
ALGORITMO BASADO EN IA PARA EL RECONOCIMIENTO FACIAL EN BOVINOS DE LA SABANA DE BOGOTÁ

AUTOR:
PABLO ESTEBAN GUTIÉRREZ RIVERA

TRABAJO DE GRADO PARA OPTAR POR EL TÍTULO DE INGENIERO
ELECTRÓNICO

DIRIGIDO POR:
FRANCISCO CARLOS CALDERÓN BOCANEGRA, PhD



PONTIFICIA UNIVERSIDAD JAVERIANA
FACULTAD DE INGENIERÍA
DEPARTAMENTO DE INGENIERÍA ELECTRÓNICA
BOGOTÁ D.C.
2024

RECTOR DE LA UNIVERSIDAD: LUIS FERNANDO MÚNERA CONGOTE, S.J.

DECANO DE LA FACULTAD DE INGENIERIA: LOPE HUGO BARRERO, Sc.D.

DIRECTOR DE LA CARRERA: JULIÁN DAVID COLORADO MONTAÑO, PhD

DIRECTOR DE PROYECTO: FRANCISCO CARLOS CALDERÓN
BOCANEGRA, PhD

Artículo 23 de la resolución No. 13 de junio de 1946

“La universidad no se hace responsable de los conceptos emitidos por sus alumnos en sus proyectos de grado. Solo velará porque no se publique nada contrario al dogma y la moral católica y porque los trabajos no contengan ataques o polémicas puramente personales. Antes bien, que se vea en ellos el anhelo de buscar la verdad y la justicia”.

AGRADECIMIENTOS

Llegar al final de este trabajo de grado es un momento de inmensa satisfacción y orgullo, y no hubiera sido posible sin la ayuda y el apoyo de grandes personas.

Primero, quiero expresar mi más profundo agradecimiento al ingeniero Francisco Calderón, mi tutor. Su conocimiento y experiencia fueron una guía fundamental durante todo el proceso y siempre estaré agradecido por su dedicación. Igualmente a la ingeniera Luisa García. Su paciencia, orientación y apoyo constante han sido fundamentales.

También quiero agradecer a mis profesores y profesoras de la facultad de Ingeniería. A lo largo de mi carrera, me han brindado no solo conocimientos, sino también herramientas esenciales para mi crecimiento académico y personal. Su compromiso y pasión por la enseñanza han sido una fuente constante de inspiración.

A mis compañeros de clase, quienes compartieron conmigo innumerables horas de estudio y trabajo en equipo. Gracias por su apoyo mutuo y por hacer de este recorrido una experiencia tan enriquecedora y memorable.

A mis amigos, que siempre estuvieron ahí para darme aliento en los momentos de estrés y dificultad. Gracias por celebrar cada pequeño logro conmigo y por su comprensión infinita.

A mi familia, mi pilar fundamental. A mis padres, por su amor incondicional, por creer en mí y por brindarme todo el apoyo necesario para completar mi educación. A mi hermana, por su constante ánimo y por ser una fuente de inspiración y motivación en mi vida.

Finalmente, quiero agradecer a la entidad Agrosavia por su colaboración en la realización de este proyecto y el apoyo que brindan a las diferentes investigaciones en busca de un futuro innovador para el campo colombiano. Su ayuda y los recursos proporcionados fueron cruciales para el desarrollo de este trabajo de grado.

A todos ustedes, muchas gracias por estar a mi lado y por ser parte de este importante logro en mi vida.

Índice

	Página
1. Introducción	1
2. Descripción del Problema	3
3. Objetivos	5
3.1. Objetivo General	5
3.2. Objetivos Específicos	5
4. Requerimientos	6
5. Estado del Arte	7
6. Marco Teórico	10
6.1. Reconocimiento facial	10
6.1.1. Autenticación de rostros	10
6.1.2. Identificación de rostros	10
6.2. Detección de rostros	10
6.3. Algoritmo de Viola – Jones	11
6.4. Redes neuronales	11
6.4.1. Redes neuronales prealimentadas	12
6.4.2. Algoritmos de retro propagación	12
6.4.3. Redes neuronales convolucionales	12
6.5. Deep Learning para identificación	14
6.5.1. One-shot learning	14
6.5.2. Redes siamesas	15
6.6. Ejemplos usados en animales	17
6.7. Librerías y Herramientas	18
6.8. Alternativas de desarrollo	18
6.8.1. Segment Anything Model (SAM)	18
6.8.2. UNET	20
6.8.3. YOLO	21
7. Solución propuesta	23
7.1. Descripción general de la solución	23
7.2. Modelo Conceptual	25
7.3. Estándares de la solución	26
7.4. Condiciones de diseño, pruebas y evaluación	27
7.4.1. Condiciones de diseño	27
7.4.2. Condiciones de prueba	28
7.4.3. Condiciones de evaluación	28

8. Diseño	31
8.1. Descripción general del diseño	31
8.2. Diagramas de bloques	31
8.3. Descripción de los bloques	32
8.3.1. Arquitectura de la red para detección implementada	32
8.3.2. Arquitectura de las redes siamesas implementadas	32
8.4. Diagramas de flujo	33
8.4.1. Base de datos	33
8.4.2. Detección de bovinos	37
8.4.3. Identificación de bovinos.	40
8.5. Criterios de selección	41
9. Pruebas y resultados	42
9.1. Pruebas iniciales Redes Siamesas	42
9.2. Pruebas y resultado detección de bovinos	43
9.3. Pruebas de entrenamiento del Algoritmo basado en redes siamesas	48
9.4. Pruebas y resultado de Algoritmo basado en redes siamesas	49
10.Evaluación del proyecto	52
11.Conclusiones y recomendaciones	57
12.Referencias	58
A. Anexos	61
A.1. Tabla en excel para el registro de los bovinos.	61
A.2. Base de datos creada.	61
A.3. Cálculo de tamaño de la red neuronal.	61
A.4. Código implementado de Redes Siamesas	61
A.5. Protocolo de pruebas	61
A.6. Script realizado para etiquetado rápido	61
A.7. Código de prueba para dos imágenes fijas	61
A.8. Código para Matriz de Confusión	61
A.9. Código de prueba textual para dos imágenes aleatorias	61
A.10.Código de prueba textual para una imagen fija	61
A.11.Código para Curva ROC	61
A.12.Modelo de redes siamesas creado y entrenado	61

Índice de figuras

1.	Ejemplo Clasificación.	14
2.	Ejemplo OSL en validación de identidad.	15
3.	Estructura Redes Siamesas.	16
4.	Funciones de costo para el reconocimiento facial.	17
5.	Ejemplo aplicación SAM.	19
6.	Ejemplo aplicación UNET.	21
7.	Ejemplo aplicación YOLO.	22
8.	Diagrama de bloques.	23
9.	Diagrama de Flujo funcionamiento detección de bovinos.	25
10.	Diagrama de Flujo funcionamiento redes siamesas.	26
11.	Esquema Matriz de confusión	28
12.	Arquitectura de red basada en YOLOv4.	31
13.	Arquitectura de la Red Neuronal Siamesa.	31
14.	Diagrama de Flujo Filtrado de material	33
15.	Ejemplo de imágenes descartadas.	34
16.	Ejemplo de imágenes aceptadas.	35
17.	Composición general del Dataset	36
18.	Composición general de las 3 subcarpetas	36
19.	Diagrama de Flujo etiquetado para detección de bovinos	38
20.	Ejemplo de imágenes etiquetadas.	39
21.	Creación de archivos Darknet	39
22.	Diagrama de Flujo Algoritmo Redes siamesas.	40
23.	Prueba 1 con Redes siamesas genéricas.	42
24.	Prueba 2 con Redes siamesas genéricas.	43
25.	Prueba 4, Imagen de vaca original.	43
26.	Prueba 4, Imagen de vaca umbralizada.	44
27.	Prueba 4, Imagen de vaca bordeada.	44
28.	Prueba 6, Imágenes obtenidas de la detección con el modelo YOLOv4.	45
29.	Prueba 7, Imágenes corrompidas por Script.	45
30.	Prueba 8, Entrenamiento del modelo creado.	46
31.	Prueba 8, Imágenes resultado de la detección con modelo entrenado.	47
32.	Prueba 11, Gráficas de Accuracy y Loss del entrenamiento.	48
33.	Prueba 12, Predicción del modelo siamesa para mismos bovinos.	49
34.	Prueba 13, Predicción del modelo siamesa para bovinos distintos.	50
35.	Prueba 13, Predicción del modelo siamesa para bovinos similares.	50
36.	Caso 1.	51
37.	Caso 2.	51
38.	Caso 3.	51
39.	Caso 4.	51
40.	Caso 5.	51
41.	Caso 6.	51
42.	Imágenes resultado de la comparación entre bovinos a través de Redes Siamesas.	51
43.	Valores de predicciones con 2 imágenes aleatorias.	53
44.	Valores de predicciones con 1 imagen aleatoria.	54

45.	Curva ROC para rango de valores 0.0 a 1.0	54
46.	Curva ROC para rango de valores 0.01 a 0.50	56

Índice de tablas

1.	Distribución de imágenes del dataset	37
2.	Matriz de confusión con umbral 0.003	52
3.	Tamaño muestral resultante	55
4.	Matriz de confusión con umbral 0.24.	56

1. Introducción

La industria bovina y las implicaciones de esta sobre el ganado son temas complejos y amplios, que involucran aspectos económicos, sociales, ambientales y éticos. La integridad de los bovinos está relacionada con la calidad de vida que tienen los animales durante su crianza, transporte, sacrificio y procesamiento [1]. La industria bovina es el sector que se encarga de la producción, transformación y comercialización de carne y leche de ganado vacuno. Esta industria tiene una gran importancia económica y social, ya que genera empleo, ingresos, seguridad alimentaria y desarrollo rural. Sin embargo, también tiene impactos negativos sobre el medio ambiente y la salud humana, animal y vegetal [2]. Algunos de los desafíos que enfrenta la industria bovina son el aumento de la productividad y rentabilidad del sector, mediante la mejora de las prácticas de manejo animal, sanitario y reproductivo; la optimización del uso del agua, el suelo y los nutrientes; la reducción de las pérdidas y desperdicios; la diversificación de los productos y mercados; y la innovación tecnológica. La reducción de impactos ambientales del sector es otro reto que debe afrontar esta industria, mediante la disminución de las emisiones de gases de efecto invernadero (GEI) y el aumento del secuestro de carbono; la conservación y restauración de los ecosistemas naturales; la prevención y control de la contaminación del agua, el suelo y el aire; y la gestión integral de los residuos sólidos y líquidos [2].

Durante los últimos años, se ha buscado promover el bienestar animal en el sector, mediante el cumplimiento de las normas legales y éticas vigentes; la implementación de buenas prácticas ganaderas que respeten las cinco libertades de los animales (libertad de hambre y sed, libertad de incomodidad, libertad de dolor, lesiones y enfermedades, libertad de expresar un comportamiento normal y libertad de miedo y angustia); y la sensibilización y capacitación de los actores involucrados [1]. El desarrollo de soluciones tecnológicas será el plan de acción a llevar a cabo, ya que el maltrato a los bovinos durante el proceso de identificación es una práctica que afecta negativamente al bienestar animal, resultando en un proceso doloroso y que modifica la composición natural de los bovinos, además de las posibilidades de pérdida o falsificación con los métodos utilizados actualmente. Según la normativa de la Unión Europea, los bovinos deben ser identificados con dos medios de identificación, que consisten en dos crotales, uno en cada oreja, con un código único [3].

Teniendo en cuenta lo anterior, el propósito era ayudar a la identificación individual y el seguimiento de los animales en el contexto de los entornos ganaderos de la sabana de Bogotá implementando un algoritmo de Inteligencia artificial que permita el reconocimiento facial aplicado a bovinos. La principal razón es que los crotales deben colocarse de forma higiénica, segura y sin causar dolor innecesario a los animales. Sin embargo, algunos estudios han reportado que el proceso de colocación de los crotales puede provocar estrés, lesiones, infecciones, inflamaciones, hemorragias y pérdida de peso en los bovinos. Estas alteraciones pueden afectar a la calidad de la carne, ya que pueden provocar cambios en el pH, el color, la terneza y el sabor [4]. Por lo que se quiere prevenir y disminuir ese maltrato en el proceso de vida de los bovinos con un sistema que los identifique a través de una fotografía facial.

De esta manera, se creó una base de datos con muestras tomadas desde el centro de Agrosavia ubicado en el municipio de Mosquera a través de un sistema de hardware para la adquisición, posteriormente con métodos de Aprendizaje profundo enfocado hacia las redes neuronales se implementaron los algoritmos para detección e identificación que finalmente se evaluó para determinar la capacidad de este para reconocer con precisión si una vaca puede pertenecer a la base de datos con la que se entrenó el modelo. Esto tiene un impacto directo en la industria

ganadera y el bienestar de los animales. Al lograr una identificación individual precisa, permite un seguimiento más efectivo de la salud, el comportamiento y la reproducción del ganado. Esto conduce a una gestión más eficiente, reduciendo pérdidas y optimizando la producción. Además, al identificar a los bovinos de manera no invasiva, se reduce el estrés de los animales asociado con métodos tradicionales de marcado, mejorando su bienestar general.

2. Descripción del Problema

La industria ganadera es un sector de la economía al cual, a lo largo de los últimos años, se le ha puesto la lupa debido a las dificultades que presenta con relación a los derechos de los animales y el trato que estos reciben a lo largo de sus vidas. Si bien este sector de producción es uno de los más grandes a nivel mundial por la alta demanda que presentamos diariamente para satisfacer nuestras necesidades alimenticias, las condiciones de vida de los animales presentes en esta industria se ven gravemente afectadas con el propósito de convertirlos en materias primas para nuestras comidas diarias. Uno de los animales que se han visto más perjudicados han sido las vacas, las cuales, actualmente son el segundo animal de granja más usado con propósitos alimenticios solo por detrás de los pollos [5]. Se estima que a nivel mundial existan aproximadamente 1500 millones de bovinos, los cuales tienen un alto impacto en la industria ya que contribuyen a la producción de múltiples alimentos que hacen parte de nuestra dieta (las carnes que consumimos en múltiples preparaciones, los productos lácteos como la leche, el yogurt, el queso, entre otros) como también para la producción de prendas y artículos que tienen como base el cuero [5].

A lo largo de sus vidas, estos animales se ven expuestos a la crueldad y la explotación en diferentes prácticas, muchos se encuentran en condiciones de hacinamiento, en lugares en los que no se pueden mover con libertad o que incluso no cuentan con la luz del sol, a confinamientos para la sobreproducción de leche, la cual va de la mano con los procesos invasivos que afectan directamente la integridad física de los bovinos, como lo pueden ser la inseminación en búsqueda de maximizar la producción, estimularlos a través del dolor, el corte de partes de su cuerpo e incluso, en los procesos utilizados para la identificación de los animales [6]. Todos estos problemas se han ido atacando desde diferentes sectores de la sociedad, a través de leyes que velan por los intereses de todas las partes y con el fin de minimizar esas situaciones de crueldad con los animales, desde investigaciones para el desarrollo de alternativas en nuestra dieta y producciones más consientes con los seres vivos e incluso movimientos que se esfuerzan por incentivar el poner fin al consumo de los animales [7]. No obstante, en el apartado de la identificación del ganado no se han producido mayores cambios en las últimas décadas, ya que se continúan utilizando estrategias que vulneran partes del cuerpo de los animales como lo son las marcas auriculares, las cuales son las más usadas en todo el mundo. Esta identificación es necesaria no solo para reconocer a cada individuo del ganado, sino para poder realizar una trazabilidad de sus características, su pasado, tener un control sobre el recorrido que ha tenido el animal y poder tener un seguimiento a los factores relevantes en sus vidas [8].

En nuestro contexto colombiano, el sector ganadero del departamento de Cundinamarca es uno de los más importantes a nivel nacional. El departamento se encuentra entre los primeros diez con mayor cantidad de cabezas de ganado con un 5,1 % y en los primeros lugares en cuanto a cantidad de terrenos ganaderos que se ubica entre 45.000 y 50.000 aproximadamente [9]. Un buen porcentaje de ganadería se concentra en la sabana de Bogotá, alcanzando un 10,2%, mientras que el restante se distribuye en los demás municipios del departamento con una menor densidad [10]. No obstante, existe también un problema para estos asentamientos de ganado. Al estar tan cerca de la capital y de localidades aledañas con una alta concentración de personas, se ha convertido en víctima de complicaciones en su producción y crecimiento. Esto debido a que la inseguridad y el desconocimiento (o desentendimiento) de los productores con sus bovinos producen pérdidas a nivel económico y dificultades para que Cundinamarca pueda continuar creciendo en la producción ganadera [11][12].

Un reciente informe de la Federación Colombiana de Ganaderos (FEDEGAN) advierte que el problema continúa, pese a las acciones emprendidas por la Policía Nacional. Amplias regiones ganaderas del país siguen siendo azotadas por bandas criminales que encuentran en el robo de ganado una fuente inmejorable de ingresos ilícitos. Solo en 2022, asegura el gremio, fueron robadas la impresionante cifra de 1.350 cabezas de ganado y en lo que va del presente año esa cifra ya está en los 322 bovinos hurtados por bandas que también se dedican a delitos como la minería ilegal, la extorsión, el secuestro y el narcotráfico. Pero no solamente es el robo de ganado sino el tráfico de carne. Señala FEDEGAN que la Policía incautó más de una tonelada de carne que era transportada “por carreteras y trochas en condiciones ilegales y sin las debidas condiciones sanitarias”, lo que permitió a los criminales lavar más de 2.400 millones dólares en el mercado negro de carne de res [13]. Si estas dificultades siguen atentando en contra del avance de la producción, sumando los fenómenos ambientales que cada vez son más complejos e impredecibles, pueden provocar graves afectación a los campesinos (pequeña y/o mediana empresa) como a las industrias encargadas de los negocios con estos animales, lo cual, causaría a gran escala que la sabana de Bogotá reduzca sus capacidades de producción, afectando el posicionamiento de Cundinamarca en este negocio [14].

Es esta la motivación por la cual se buscaron estrategias apoyadas en la inteligencia artificial para fortalecer y brindar estrategias para el registro y reconocimiento del ganado. En conjunto con una red que permita integrar al sector campesino, produciendo una base de datos nutrida con las vacas de la región, ayudarán a la creación de una solución capaz de identificar a los bovinos. La implementación de sistemas de reconocimiento facial en la ganadería puede generar dudas éticas, especialmente en lo que respecta al bienestar animal. Sin embargo, en este proyecto es importante realizar un análisis objetivo y considerar las posibilidades de esta tecnología.

Dentro de los beneficios potenciales, el reconocimiento facial en animales ofrece una mejora significativa en la trazabilidad del ganado. Esta tecnología permite la identificación y seguimiento individual de cada animal, simplificando el control de su salud, producción y linaje. Además, posibilita la detección temprana de enfermedades al identificar anomalías en el comportamiento o apariencia de los animales, lo que facilita una intervención rápida ante cualquier problema de salud o lesión. En términos de gestión del rebaño, el reconocimiento facial contribuye a optimizar esta tarea al identificar animales con características específicas o necesidades particulares. Finalmente, al eliminar la necesidad de marcar o tatuar a los animales, esta tecnología reduce el estrés asociado a estas prácticas, promoviendo un ambiente más cómodo y menos intrusivo para el ganado. En cuanto a las consideraciones éticas, fue esencial abordar varios puntos clave. Fue crucial garantizar que la implementación de estas tecnologías no cause ningún tipo de dolor o sufrimiento a los animales. La instalación de cámaras y otros dispositivos se llevó a cabo de manera segura y respetuosa, sin causar molestias innecesarias ya que era en una zona donde las vacas no se vieran obstaculizadas y siguieran su recorrido normal. Por último, el bienestar animal debe ser el foco principal al utilizar esta tecnología. Esto implica que cualquier aplicación de reconocimiento facial en animales debe integrarse dentro de un enfoque más amplio de cuidado y respeto hacia los animales, priorizando su salud y comodidad.

3. Objetivos

3.1. Objetivo General

Implementar un algoritmo fundamentado en la inteligencia artificial que permita el reconocimiento facial aplicado a bovinos, esto con el propósito de ayudar a la identificación individual y el seguimiento de los animales en entornos ganaderos de la sabana de Bogotá.

3.2. Objetivos Específicos

- Crear una base de datos que potencie el entrenamiento de los modelos en inteligencia artificial mediante la recopilación de muestras específicas del sector, para su aplicación en la identificación de rostros de bovinos y el conteo de moscas sobre el animal.
- Implementar un modelo de Aprendizaje profundo seleccionado del estado del arte enfocado en el reconocimiento facial para la identificación de cada uno de los bovinos.
- Evaluar los resultados obtenidos por el algoritmo de reconocimiento facial a partir de la matriz de confusión obtenida de la base de datos.

4. Requerimientos

- Reconocer el tipo de vacas que se encuentran en el lugar, esto debido a que hay múltiples razas de bovinos y entre ellas pueden cambiar características que pueden ser cruciales para su identificación (color o manchas presentes en el rostro, tamaño de su cráneo, características del rostro, su fisionomía, entre otros).
- Documentar el desarrollo del proyecto, incluidos los detalles del conjunto de datos, la arquitectura del modelo, los resultados de entrenamiento y validación, y las conclusiones del proyecto.
- Realizar un sistema de hardware que permita recopilar y guardar las muestras de los bovinos durante un tiempo aproximado de un mes.
- El modelo debe ser capaz de aprender a reconocer patrones específicos en las imágenes para identificar a cada bovino de manera única.
- Hacer un correcto preprocesamiento a las imágenes obtenidas para así, contar con las características idóneas para trabajar con los modelos de inteligencia artificial.
- Etiquetar de forma adecuada las muestras obtenidas ya que esto aporta a la futura identificación de las vacas.

5. Estado del Arte

Para el proceso de reconocimiento facial a través de la detección de características, se han realizado e implementado diversos métodos. Sin embargo, se ha encontrado en las técnicas de Aprendizaje profundo una herramienta de gran utilidad. En [15] se comenta acerca de la biometría animal, la cual es un campo emergente en la visión por computadora, el reconocimiento de patrones y la ciencia cognitiva. Los métodos tradicionales para extraer características de textura y representaciones basadas en apariencia enfrentan dificultades en entornos complejos. El aprendizaje profundo ha llamado la atención para reconocer animales mediante señales visuales. Se introduce un método basado en el aprendizaje profundo para identificar individuos de ganado mediante el análisis de imágenes únicas de su morro (patrón de nariz) utilizando redes neuronales convolutivas. Esto ayuda a prevenir errores como animales omitidos o intercambiados presentando una característica importante y única en los bovinos. Así mismo, en [16] y en [17] se utilizó el aprendizaje profundo para reconocer ovejas utilizando redes neuronales convolucionales. En el primero, utilizando biometría facial, se probaron diferentes diseños de redes y se optimizaron los parámetros utilizando métodos bayesianos. Este estudio también exploró la configuración de AlexNet y empleó técnicas de aumento de datos en un conjunto de 52 ovejas, generando 1000 imágenes de entrenamiento/validación por oveja. Los experimentos lograron una precisión del 98 %, superando los métodos de identificación previos. De esta manera, se probaron 2 métodos diferentes que demostraron la capacidad de los algoritmos en obtener una precisión cercana al 100 % para la identificación y reconocimiento de los animales. Igualmente, para llevar a buen término estos procedimientos, se propone contar con una estrategia en la toma de imágenes frente al individuo donde se incluye la distancia a la cámara.

Las redes neuronales convolucionales son una buena solución pero que pueden llegar a consumir un alto porcentaje de recursos computacionales. En el segundo, se presenta un experimento con cuatro arquitecturas diferentes de redes neuronales convolucionales que tienen como objetivo clasificar segmentos de una oveja utilizando un conjunto de datos de superpíxeles. La propuesta utilizó un conjunto de imágenes con 512 imágenes de 32 ovejas. En este conjunto de imágenes, aplicamos la técnica de Clustering Iterativo Lineal Simple con un parámetro de número K de 600 para generar el conjunto de datos de superpíxeles que luego se procesó en las redes neuronales profundas. Se seleccionaron cuatro arquitecturas para entrenar los modelos: VGG16, ResNet152V2, InceptionV3 y DenseNet201. El experimento se llevó a cabo utilizando validación cruzada con cinco divisiones, separando el conjunto de datos en entrenamiento (60 %), validación (20 %) y prueba (20 %).

El mejor resultado presentado provino del enfoque con la técnica DenseNet201 con un valor F de 0.928. Es posible resaltar las contribuciones de esta investigación como una metodología para segmentar imágenes de ovejas de raza mixta utilizando redes neuronales convolucionales y proporcionar un método no invasivo que puede respaldar otras implementaciones. De otro modo, en [18] se menciona que, actualmente, se están llevando a cabo investigaciones sobre el uso de redes neuronales profundas en la biometría para abordar la autenticación de la identidad del ganado, específicamente el reconocimiento facial no invasivo. Sin embargo, debido al gran tamaño de estos modelos, no son fácilmente desplegados en sistemas integrados con recursos

limitados. Para abordar este problema, se ha desarrollado en este estudio una red neuronal compacta optimizada para sistemas integrados. Consiste en seis capas convolucionales que utilizan convoluciones escalonadas para el agrupamiento. El modelo resultante tiene 0.17 millones de parámetros y un tamaño de 2.01 MB. Se recopilieron un total de 10,239 imágenes de caras de ganado para construir el conjunto de datos. Los resultados experimentales demuestran una precisión del 98.37 %, con un tiempo de detección de 300 ms por imagen en una Raspberry Pi.

Esta red neuronal liviana mejora la precisión del reconocimiento facial del ganado y reduce eficazmente la carga computacional. Este resultado demuestra una alternativa de procesamiento que utiliza menores recursos computacionales, produciendo una solución más rápida sin perder el objetivo de un buen desempeño. Por otra parte, en [19] se presenta un nuevo modelo de identificación de ganado utilizando características de textura de patrón binario local (LBP). El algoritmo fue entrenado con imágenes faciales en escala de grises de 30 cabezas de ganado, abordando variaciones de iluminación y alineación. Se utilizó un método de alineación robusto y el rendimiento se evaluó utilizando la distancia ponderada de Chi cuadrado. El descriptor LBP mostró un reconocimiento facial de ganado eficiente y preciso. Además, muestra una forma de procesamiento donde se resalta lo más importante de la fotografía como el rostro de la vaca y lo demás lo ignora otorgando un peso a cada píxel. Determina un número aproximado de imágenes por vaca para el entrenamiento, específicamente 90. No obstante, para eliminar el ruido de imágenes, en este caso de reconocimiento facial, existe la técnica anteriormente mencionada, la red neuronal convolucional, como se presenta en [20].

En comparación con la reducción de ruido en imágenes tradicional, las redes neuronales convolucionales (CNN) ofrecen una reducción de ruido superior. Sin embargo, persiste un problema significativo: la imagen residual aprendida, que captura las diferencias entre el ruido y la limpieza, contiene detalles importantes que se pierden en la imagen tratada. Para abordar esto, el artículo propone una red neuronal convolucional de extremo a extremo que preserva los detalles (DRCNN) al derivar un modelo matemático de un problema de minimización. A pesar de que esta técnica de limpieza en las imágenes de prueba suele mejorar el desempeño, resulta complejo desarrollar esta solución durante la implementación matemática en software. Igualmente, en [21] se investigó el potencial de las CNN de valores complejos para la reducción de ruido en imágenes. Se desarrolla una CNN que, a partir de sus operaciones matemáticas claves definidas en el campo de los números complejos para aprovechar las ventajas de las operaciones de valores complejos, incluyendo la compacidad de la convolución dada por el producto tensorial de filtros de valores complejos de 1D, aporta a la minimización del ruido presente en las fotografías analizadas.

Los resultados experimentales muestran que la CNN de reducción de ruido de valores complejos propuesta tiene un rendimiento competitivo en comparación con las CNN de reducción de ruido de valores reales de última generación, con una mayor robustez ante posibles inconsistencias de los modelos de ruido entre las muestras de entrenamiento y las imágenes de prueba. No obstante, en [22] se realizaron unas pruebas con ganado Holstein-Friesian, lo que hace posible utilizar las características empleadas ya que esta raza de vaca pertenece a la zona

de nuestro estudio. Esta raza de ganado presenta patrones únicos en su pelaje, en blanco y negro. Este estudio utiliza estas marcas naturales para automatizar la detección e identificación de vacas individualmente mediante el uso de redes neuronales convolucionales y técnicas avanzadas de aprendizaje profundo de métricas. A diferencia de los enfoques actuales que necesitan etiquetas o dispositivos, esta metodología permite identificar, localizar y distinguir a las vacas sin necesidad de contacto, usando imágenes aéreas en pastizales abiertos. Incluso cuando se introducen nuevas vacas, no es necesario volver a entrenar el sistema. La aplicación de aprendizaje profundo de métricas demuestra su eficacia al lograr una precisión del 93.8 %, habiéndose entrenado solo con la mitad del grupo de vacas.

Este avance facilita la supervisión no invasiva del ganado, con aplicaciones en agricultura de precisión, seguimiento de la productividad e investigación veterinaria. Finalmente, gracias al poder de las CNN, en [23] y [24] se han implementado cascadas para el reconocimiento facial. En el primero, se propone una arquitectura en cascada construida sobre redes neuronales convolucionales (CNN) con una capacidad discriminativa muy poderosa, al tiempo que mantiene un alto rendimiento. La cascada de CNN propuesta opera en múltiples resoluciones, rechaza rápidamente las regiones de fondo en las etapas de baja resolución rápida y evalúa cuidadosamente un pequeño número de candidatos desafiantes en la última etapa de alta resolución. Para mejorar la efectividad de la localización y reducir el número de candidatos en etapas posteriores, se introduce una etapa de calibración basada en CNN después de cada una de las etapas de detección en la cascada. La salida de cada etapa de calibración se utiliza para ajustar la posición de la ventana de detección para la entrada a la etapa subsiguiente. En el segundo, se menciona que la cascada se ha utilizado ampliamente en la detección de rostros, donde primero se emplea un clasificador de bajo costo computacional para reducir la mayor parte del fondo mientras se mantiene la recuperación. La cascada en la detección fue popularizada por el influyente marco Viola-Jones y luego ampliamente utilizada en otros procesos, como DPM y CNN. Se propone un entrenamiento conjunto para lograr una optimización de extremo a extremo para la cascada de CNN. Se muestra que el algoritmo de retro propagación utilizado en el entrenamiento de CNN se puede utilizar de manera natural en el entrenamiento de cascada de CNN. Se presenta cómo se puede llevar a cabo el entrenamiento conjunto en una cascada de CNN ingenua y en una red de propuesta de región (RPN) más sofisticada y en Fast R-CNN. Los experimentos en bancos de pruebas de detección de rostros verifican las ventajas del entrenamiento conjunto.

6. Marco Teórico

Para comprender los conceptos claves y las temáticas abordadas para la implementación del proyecto, se destacaron las siguientes nociones que aportan al entendimiento de los procedimientos que respaldan los objetivos a desarrollar:

6.1. Reconocimiento facial

El reconocimiento facial es una técnica de biometría que se utiliza para identificar a una persona o animal a través de su rostro. Esta herramienta ha sido desarrollada desde 1995, siendo utilizada actualmente como forma de seguridad biométrica, debido a que sus avances han mejorado su porcentaje de exactitud a la hora de determinar si el individuo que se está analizando corresponde con la etiqueta almacenada en el modelo utilizado. Los modelos para implementar el reconocimiento facial tienen como base la toma de muestras del rostro de la persona o animal a analizar, estas son obtenidas a partir de fotografías o fotogramas extraídos de un video. Una vez identificadas las características presentes en el rostro, se valida con imágenes presentes en una base de datos, las cuales se comparan con las muestras obtenidas para verificar si corresponde con la identidad registrada [25]. Las operaciones realizadas por estos algoritmos buscan que, dado que se tiene a la entrada del sistema una cara desconocida, se busca dentro del data set del modelo un rostro con características iguales o similares para verificar la identificación del individuo y producir un resultado a la salida que ilustre la precisión del modelo para ejecutar el reconocimiento facial. Las dos principales opciones a la hora de desarrollar un algoritmo para reconocimiento facial son las siguientes:

6.1.1. Autenticación de rostros

En este proceso, se toma la muestra que se quiere identificar y se compara con una imagen para observar sus coincidencias o discrepancias. Al realizar el análisis en paralelo de ambas imágenes, el modelo da una respuesta positiva en caso de que ambas coincidan, mientras que, si se encuentra un mayor número de discrepancias, el resultado debe ser negativo.

6.1.2. Identificación de rostros

A diferencia del procedimiento mencionado anteriormente, el proceso de identificación de rostros se produce cuando a partir de una imagen a la entrada del modelo, se busca un rostro en la base de datos que cumpla con las características que presenta la imagen y así, asignar una identidad válida a la persona en caso de estar presente en la base de datos o determinarla como desconocida para el modelo.

6.2. Detección de rostros

Para poder ejecutar los algoritmos de reconocimiento, se debe realizar una detección facial ya que, este proceso nos ayuda a determinar la posición en la imagen del rostro y obtener un estimado acerca del tamaño que este tiene. Este proceso de localización se produce ya sea en imágenes o en videos; es fundamental para el reconocimiento contar con una buena tecnología que nos brinde un primer acercamiento al rostro, su tamaño y posición, ya que esto producirá características relevantes a partir del método utilizado:

- Métodos basados en el conocimiento: Se tienen en cuenta la posición y las distancias entre sus ojos, labios o nariz.
- Métodos basados en características invariantes: Se definen como características invariantes aquellas partes o propiedades del rostro que no cambian con la toma de la imagen, la posición en el rostro y las cualidades que otorgan al rostro. Algunas de estas características son las cejas, la posición de la nariz, las texturas o colores asociados al rostro, entre otras.
- Métodos basados en patrones: A partir de un molde previamente definido para el algoritmo, se toma una imagen a la entrada para obtener las características en común entre ellos dos [26].

6.3. Algoritmo de Viola – Jones

Este algoritmo fue desarrollado en el año 2001 por Paul Viola y Michael Jones. Esta técnica es ampliamente utilizada para la detección de rostros debido a que, aplicado a imágenes de humanos, es capaz de detectar rápidamente los rostros humanos. Su valor añadido es que aplica una clasificación a la imagen en escala de grises, lo cual reduce en gran medida el procesar la imagen a color y píxel por píxel. Con este procesamiento, extrae las principales características de la imagen para diferenciar entre el rostro detectado y los demás elementos de la fotografía [27].

6.4. Redes neuronales

Las redes neuronales son métodos basados en inteligencia artificial con los cuales se busca que la máquina sea capaz de procesar datos de forma análoga a como lo hace el cerebro humano. Es ampliamente utilizado en procesos de aprendizaje de máquina y Aprendizaje profundo, se componen de múltiples nodos o neuronas que se conectan entre sí a diferentes niveles o capas. Estas redes buscan que los algoritmos implementados en ellas sean capaces de aprender y mejorar en caso de que se cometan errores. Actualmente, el uso de las redes neuronales se centra en la resolución de problemas complejos como el procesamiento de lenguaje natural (un ejemplo de esto podría ser la generación de un resumen de un documento) y el reconocimiento facial. Como se mencionó anteriormente, la arquitectura de las redes neuronales está basada en un modelo similar al planteado para el cerebro humano, se tienen múltiples neuronas a diferentes niveles las cuales forman una red compleja e interconectada capaz de resolver o ejecutar algoritmo que, en esencia son sistemas fundamentados en cálculos matemáticos. Podemos definir las siguientes capas en las redes neuronales:

- Capa de entrada: Es la capa que relaciona la red neuronal con la información presente en el mundo exterior, de tal forma que, esta capa debe estar en capacidad de procesar y analizar los datos que están ingresando para trabajar con ellos en las capas posteriores.
- Capa o capas ocultas: Las capas ocultas se encargan de recibir la información procesada por la capa previa para continuar reforzando y ejecutando el algoritmo de la red, de forma tal que entreguen a la siguiente capa una mejora con respecto a la anterior.
- Capa de salida: Como su nombre lo indica, esta capa entrega el resultado final de la red neuronal. Esta puede estar compuesta por más de una neurona, dependiendo del

problema de clasificación que se esté abordando. Por ejemplo, si se tiene un problema de clasificación binaria (sí o no, uno o cero) con una sola neurona bastaría para entregar el resultado en la capa de salida, mientras que en problemas multiclase, se necesita de más de un nodo para poder abordar las múltiples salidas de la red.

En las redes neuronales, encontramos tres tipos diferentes, las cuales se diferencian entre sí por su método de encaminar los datos desde el nodo de entrada hasta el nodo de salida [28].

6.4.1. Redes neuronales prealimentadas

Este tipo de redes neuronales se caracterizan por realizar el procesamiento de los datos en una sola dirección, iniciando por la capa o nodo de entrada de la red, a través de las diferentes capas y finalizando en el o los nodos de salida. Otra característica relevante en este tipo de redes es que todas las neuronas de una capa deben estar conectadas con las de la capa siguiente. Para mejorar los resultados de este tipo de redes en el tiempo, es posible utilizar procesos que den retroalimentación a la red.

6.4.2. Algoritmos de retro propagación

Para el aprendizaje de las redes neuronales se utilizan bucles de retroalimentación con los cuales es posible corregir los errores que se pueden presentar y favorecer al análisis predictivo de estas redes. Algo característico de este tipo de algoritmos para la construcción de redes neuronales es que los datos fluyen a través de todas las capas y neuronas presentes en la red, no obstante, solo hay un camino correcto entre los nodos de entrada y salida de la red. Este proceso se hace a través de iteraciones en las cuales, los nodos realizan una predicción del siguiente nodo en la red, de tal forma que, si la suposición es correcta, se asigna un mayor peso a esa conexión mientras que las conexiones erróneas, se asignan menores pesos, esto para establecer la ruta correcta entre las capas [29].

6.4.3. Redes neuronales convolucionales

Este tipo de redes neuronales han sido utilizadas principalmente en aplicaciones que procesan imágenes y señales de audio, como por ejemplo las de la voz. Este tipo de arquitectura es ampliamente usada en Aprendizaje profundo gracias a la capacidad que poseen para aprender a partir de los datos que tienen a su entrada. Estas redes tienen tres tipos de capas, las cuales son:

- Capa convolucional: Por lo general, este tipo de capa se encuentra a la entrada o en las primeras capas de la CNN. Se caracteriza por ser el bloque base de la red neuronal convolucional, debido a que son las encargadas de hacer la mayor parte de los cálculos. Para la conformación de estas capas, se requiere de elementos como los datos de entrada de la red, un filtro para tener un primer análisis de las entradas y un mapa de características. Un ejemplo de este primer bloque puede ser aplicado al trabajo con imágenes a color, donde podemos encontrar los datos de entrada de la red, los cuales se componen de la matriz de píxeles que componen la imagen. Con esto podemos definir las dimensiones de entrada de la red, las cuales son las medidas de ancho, alto y profundidad de la matriz, teniendo en cuenta la composición RGB de esta. Posterior a los datos de entrada, tenemos un primer preprocesamiento en el cual, la imagen pasa por un filtro que es llamado

kernel, el cual, toma los datos introducidos a la red y los procesa en busca de características que pueda identificar a través de las dimensiones de la imagen. Este proceso, recibe el nombre de convolución. En esta etapa, la red ejecuta una serie de cálculos a partir del kernel utilizado, de forma tal que el resultado que entrega sea un producto escalar entre los datos de entrada y el filtro, con el cual, podremos extraer características de la imagen procesada. El resultado de estas operaciones va otorgando pesos a determinadas zonas, de forma tal que, las capas posteriores puedan enfocar su trabajo o sus cálculos en los campos donde la capa anterior encontró mayor relevancia. Esto genera que se trabaje con más de una capa convolucional y que se presente una jerarquía entre ellas, ya que como se mencionó en el ejemplo, el trabajo y los resultados obtenidos por una, determinan los datos a la entrada de la siguiente, siguiendo un procesamiento que va de lo general a lo específico.

- Capa de agrupación: Las capas de agrupación, también conocidas como capas de muestreo o submuestreo, están definidas para reducir la dimensionalidad de los datos ingresados a la CNN. Este tipo de capas realiza un proceso similar al filtrado que ejecuta la capa convolucional, debido a que también debe realizar un barrido a lo largo de los datos de entrada. No obstante, este proceso no asigna valores o pesos, su trabajo se enfoca en buscar como optimizar el número de parámetros a utilizar a la entrada, aplicando una función de agregación a los resultados obtenidos en las capas convolucionales, para así, determinar que valores de ese campo resistivo se pueden optimizar. Este tipo de capas están enfocadas en la reducción de la complejidad de la red neuronal, minimizando los parámetros para tener en cuenta para su procesamiento, lo cual beneficia también al costo computacional o la eficiencia que tiene la red para ejecutar los cálculos. Además, estas capas ayudan a que no se produzca un sobreajuste a los datos de entrada, ya que esto puede condicionar el funcionamiento de la red neuronal.
- Capa totalmente conectada: Esta capa suele encontrarse al final de la red neuronal, ya que cada una de las neuronas o nodos pertenecientes a esta capa, deben estar conectados a la salida de la red. Esta capa se encarga de la clasificación teniendo en cuenta las características que se han ido calculando y obteniendo en las capas previas una vez aplicados los filtros y hecha la asignación de los pesos para que el proceso de esta o estas capas se vea reducido a la clasificación, usando funciones que sean capaces de asignar probabilidades entre uno y cero a la salida de la red [30].

Como se mencionó anteriormente en un ejemplo, el funcionamiento de estas redes neuronales convolucionales está sujeto al uso de decenas o centenares de capas. En el procesamiento con imágenes, cada capa debe ser capaz de aprender a identificar diferentes características de la imagen de entrada. En cuanto al filtrado de la imagen, estos procesos pueden ir desde acciones que implican la modificación de la resolución de la imagen para reducir el costo de su procesamiento, lo cual puede brindar información acerca de las zonas de mayor interés de la imagen para facilitar el trabajo a las capas posteriores. Este filtrado puede seguir creciendo en complejidad, iniciando con características propias de la imagen como el valor de los píxeles, el brillo o la identificación de los bordes de algunos elementos presentes en la imagen, como finalizar en un estimado de la forma singular que se busca analizar. Por lo general, las capas encargadas de las convoluciones van de la mano con una función de activación, la cual se encarga de mantener los resultados escalares de cada capa en valores positivos, lo cual aporta

a que el entrenamiento pueda realizarse de forma eficaz. Una de las funciones de activación más utilizadas se conoce como la Unidad Lineal Rectificada o ReLU, cuyo principal valor añadido es el de activar únicamente las características que deben continuar a la siguiente capa, manteniendo los resultados positivos de los cálculos mientras que los negativos los iguala a cero. Con esto, las capas encargadas de la agrupación o muestreo se enfocan principalmente en las características que fueron “activadas” posterior a la convolución y aportan a la rapidez del procesamiento de la imagen. Este proceso se replica en la mayoría de las capas hasta llegar a la etapa de las totalmente conectadas [31].

6.5. Deep Learning para identificación

Los sistemas de aprendizaje profundo, los cuales logran que el computador aprenda los descriptores directamente de los datos de entrada, creando sistemas más independientes. A pesar de que la propuesta de estos algoritmos no es nueva, es relativamente reciente que se utilizan con frecuencia gracias a los impresionantes resultados que se obtienen en diferentes tareas y a su habilidad de generalización. En muchas ocasiones es posible utilizar redes entrenadas en cierta tarea para otra similar sin realizar un gran cambio en los algoritmos. Estos métodos aprenden directamente de los datos de entrada por lo que es necesario que exista una gran base de datos para su entrenamiento, lo que en ocasiones no resulta viable.

6.5.1. One-shot learning

El avance sobresaliente de los algoritmos de aprendizaje profundo se debe en parte al acceso a bases de datos extensas que contienen múltiples imágenes para cada categoría a estudiar. Para lograr una clasificación precisa, se requiere una amplia variedad de imágenes representativas de cada categoría, capturadas bajo diversas condiciones de iluminación, ángulos, ubicaciones y con distintas características. Esto permite que el algoritmo pueda generalizar su conocimiento y reconocer patrones incluso en situaciones nuevas y desconocidas.

En el contexto de la clasificación, el objetivo es determinar la probabilidad de que un objeto pertenezca a una categoría específica. Por ejemplo, en una tarea de reconocimiento de imágenes, el sistema debe ser capaz de identificar si una imagen dada corresponde a la categoría 'gato' entre otras opciones como 'perro', 'caballo', entre otras.




Figura 1: Ejemplo Clasificación.

Por otro lado, en el ámbito de la comparación, el enfoque se centra en determinar si dos objetos son idénticos. Para la validación de identidad, esta pregunta se traduce en: ¿La persona es quien afirma ser? Esta cuestión admite únicamente dos respuestas: sí o no. El One-shot learning surge como respuesta a la necesidad de aprender las características relevantes para

una tarea específica utilizando una única muestra por clase en la base de datos. Estos algoritmos se inspiran en la capacidad humana de aprender sin necesidad de ser expuestos a un gran número de ejemplos. Actualmente, este campo de estudio está muy activo, con numerosas publicaciones dedicadas al tema.

Este enfoque resulta especialmente útil en aplicaciones como el reconocimiento facial, donde los sistemas suelen contar con una única imagen de referencia para comparar. Requerir al usuario que proporcione múltiples imágenes de su rostro en diversas poses, edades o con cambios de apariencia, no solo sería poco práctico en términos de usabilidad, sino que también podría infringir su derecho a la privacidad. En la Figura 2 se ilustra un ejemplo de one-shot learning, donde la base de datos contiene registros de personal identificado por ReconoSER ID. En este escenario, el acceso se concede a aquellos que están inscritos y se deniega a los que no lo están.




Figura 2: Ejemplo OSL en validación de identidad.

6.5.2. Redes siamesas

Las redes siamesas surgieron como una solución al problema de autenticación de rostros y validación de identidad a partir de las características biométricas extraídas de imágenes. Estas redes se caracterizan por tener dos ramas de redes neuronales convolucionales (CNN) que funcionan en paralelo, compartiendo los mismos pesos y parámetros para garantizar una extracción uniforme de características. Cada rama de la red produce una función de costo que permite evaluar las diferencias entre las imágenes procesadas.

- 6.5.2.1 Estructura y funcionamiento: Las redes siamesas representan una solución innovadora al desafío de la autenticación facial y la validación de identidad mediante el análisis de características biométricas obtenidas de imágenes. Estas redes están formadas por dos redes neuronales convolucionales (CNN) que funcionan en paralelo, compartiendo los mismos pesos para garantizar una extracción uniforme de características. Cada CNN produce una función de costo que, al ser comparada, permite evaluar las diferencias entre las imágenes procesadas. Si las imágenes pertenecen a la misma persona, la discrepancia entre las funciones de costo será mínima; en cambio, si corresponden a individuos distintos, esta diferencia se incrementará.

A diferencia de una única CNN, que necesita un gran volumen de imágenes para entrenarse y fortalecer su aprendizaje, las redes siamesas utilizan dos CNN con parámetros

idénticos, lo que reduce la necesidad de datos al centrarse en la comparación directa entre dos imágenes. Esto no solo facilita la detección de similitudes y diferencias sino que también disminuye la cantidad de muestras necesarias para el entrenamiento.

La arquitectura de una red siamesa replica ciertos componentes de una red neuronal que luego se fusionan en capas comunes, permitiendo la comparación de dos entradas, como imágenes faciales, para extraer características y aplicar un clasificador que determine si la identidad es verificada correctamente. Los primeros modelos siameses, que surgieron a principios de este siglo, empleaban técnicas de reducción de dimensiones para la comparación de imágenes. Con el tiempo, los avances en Deep Learning han introducido métodos más sofisticados para la extracción de características, pero la estructura básica de las redes siamesas ha permanecido constante, consistiendo en una parte simétrica e independiente seguida de una comparación entre ambas ramas.




Figura 3: Estructura Redes Siamesas.

- 6.5.2.2 Evolución y aplicaciones: Para fortalecer la robustez de los sistemas, se han llevado a cabo diversas investigaciones que proponen modificaciones, mejoras y análisis en las redes utilizadas para la validación de identidad. A continuación, se destacan algunos estudios relevantes:

- DeepFace: Presentado por investigadores de Facebook en 2014, este enfoque emplea herramientas de transferencia de aprendizaje y utiliza redes siamesas como extractores de características, evitando la necesidad de un entrenamiento contrastivo.
- FaceNet: Desarrollado por Google en 2015, los autores proponen una arquitectura entrenada de principio a fin y sugieren el uso de una función de costo triplet. Esta función añade una imagen adicional a la entrada del sistema, incluyendo: 1) una imagen base (Anchor), 2) una imagen positiva (de la misma identidad que la base) y 3) una imagen negativa (de una identidad diferente a la base). El objetivo es minimizar las distancias entre imágenes de la misma identidad y maximizar las distancias entre imágenes de diferentes identidades después del entrenamiento. Este método fortalece el sistema al prevenir situaciones en las que la imagen negativa está más cercana a la imagen base que la imagen positiva.
- Funciones de costo: A partir del desarrollo de la función de costo triplet, otras

funciones también se han desarrollado con el fin de mejorar este tipo de sistemas, se puede destacar, por ejemplo, Center Loss o Sphere Face , que buscan también minimizar la distancia entre imágenes de la misma identidad o RegularFace que además busca maximizar la distancia entre imágenes de identidades diferentes.




Figura 4: Funciones de costo para el reconocimiento facial.

- La interpretabilidad es un área de investigación crucial en el campo del aprendizaje automático. Con frecuencia, los algoritmos de este tipo se perciben como cajas negras, ya que no está claro cómo llegan a sus conclusiones. Sin embargo, se han realizado avances significativos en este sentido, como el trabajo llevado a cabo por investigadores de la Universidad de Michigan. Ellos han desarrollado un sistema de reconocimiento facial interpretable que utiliza descriptores para resaltar características específicas, como los ojos, la boca o la nariz, en el resultado de la comparación. Este enfoque promete proporcionar una comprensión más profunda de cómo funciona el sistema y cómo llega a sus decisiones.

Enfoques como el One-shot learning y las redes siamesas han permitido solucionar problemas de la vida cotidiana, cuando no se tiene acceso a una gran base de datos para cada una de las clases o dónde el problema que se busca solucionar es el de la comparación [32].

6.6. Ejemplos usados en animales

En el caso de los bovinos, el reconocimiento facial se ha utilizado para identificar individuos y monitorear su comportamiento. El reconocimiento facial se basa en la identificación de patrones faciales únicos en cada animal. Estos patrones pueden ser detectados mediante el análisis de imágenes digitales del hocico, la frente y las orejas del animal. Para lograr esto, se utilizan técnicas de procesamiento de imágenes y aprendizaje automático. El aprendizaje automático es una rama de la inteligencia artificial que permite a las computadoras aprender sin ser programadas explícitamente. La detección e identificación facial es un proceso que implica la detección de rostros en una imagen y la identificación de los individuos presentes en la imagen. Las técnicas basadas en Aprendizaje profundo son un conjunto de algoritmos que utilizan redes neuronales profundas para el reconocimiento facial. Una investigación llevada a cabo en la “University of New England” es la mejor aproximación al problema que buscamos solucionar, debido a que un investigador realizó un modelo fundamentado en inteligencia artificial para determinar la identidad de una vaca a partir de una imagen de su hocico. La construcción de dicho modelo se generó a partir del uso de YOLOv3, el cual es un algoritmo usado para el reconocimiento de objetos y extracción de características en imágenes, con el cual, obtuvo los patrones de los hocicos de las diferentes vacas que utilizó para su identificación y generó una base de datos con estas imágenes para posteriormente, implementar una red neuronal

convolucional basada en la arquitectura de ResNet-50, la cual entreno con la base de datos obtenida en el preprocesamiento efectuado con YOLO para finalmente, testearlo con una muestra de un hocico para que la red estableciera los patrones y fuera capaz de identificar a los bovinos [33].

6.7. Librerías y Herramientas

- **Lenguaje de Programación:** Concerniente a Deep Learning, el lenguaje más utilizado es Python, gracias al amplio número de bibliotecas y frameworks realizados para este lenguaje como son PyTorch, Caffe, TensorFlow o Keras. Por otro lado, existen diferentes bibliotecas implementadas para Python, entre estas:
 - NumPy: Enfocada hacia la computación científica, que otorga vectores o arreglos entre otras herramientas matemáticas.
 - Pandas: Enfocada hacia el análisis de datos, principalmente la lectura de los distintos archivos dataset permitiendo la lectura y tratamiento de sus datos.
 - Scikit-learn: Enfocada hacia Machine Learning que posee herramientas estadísticas muy potentes.
 - Matplotlib: Enfocada hacia la creación de gráficos, además de la visualización y obtención de imágenes.
- **TensorFlow:** Creada por Google con el fin de realizar tareas en el ámbito de Machine Learning. Es una biblioteca para cálculos numéricos mediante los diagramas de flujo de datos. Publicada en 2015, ha sido un referente en el desarrollo de sistemas Deep Learning y redes neuronales.
- **Keras:** Es una biblioteca para redes neuronales de alto nivel desarrollada para Python con el fin de simplificar el desarrollo. En 2017, Keras fue integrado en el código fuente de TensorFlow logrando su desarrollo con un nivel mayor de abstracción.
- **CUDA y cuDNN:** El desarrollo de Deep Learning se han visto facilitados por el uso de GPUs. Debido a la cantidad de cálculos que se efectúan y su gran complejidad, especialmente durante el entrenamiento de una red neuronal, es necesario un hardware con altos recursos para reducir los tiempos en comparación al uso exclusivo de CPUs. La razón principal es el número de núcleos que permiten el procesamiento de varias tareas en paralelo. De esta forma, CUDA, la arquitectura de cálculo paralelo de NVIDIA, junto a cuDNN, la librería para Deep Learning, permiten el uso de GPUs en TensorFlow [34].

6.8. Alternativas de desarrollo

6.8.1. Segment Anything Model (SAM)

Es una arquitectura de red neuronal desarrollada para abordar la tarea de segmentación semántica en imágenes. La segmentación semántica es un problema en visión por computadora que implica asignar una etiqueta a cada píxel de una imagen para indicar a qué clase pertenece. Por ejemplo, en una imagen de una calle, la segmentación semántica etiquetaría cada píxel como perteneciente a clases como .`automóvil`", `persona`", `edificio`", etc. El enfoque del modelo

SAM se centra en lograr un equilibrio entre la precisión y la eficiencia computacional en la segmentación semántica. Algunos aspectos clave del modelo SAM son:

- **Arquitectura eficiente:** SAM está diseñado para ser eficiente tanto en términos de recursos computacionales como de tiempo de ejecución. Utiliza una arquitectura de red neuronal convolucional profunda, pero implementa técnicas de diseño eficientes, como convoluciones dilatadas y capas de reducción de dimensionalidad, para reducir la carga computacional.
- **Contexto contextual:** SAM aprovecha el contexto contextual alrededor de cada píxel para mejorar la precisión de la segmentación semántica. Esto se logra mediante el uso de convoluciones dilatadas y agrupaciones de píxeles vecinos para capturar relaciones espaciales a diferentes escalas.
- **Uso de atención:** SAM utiliza mecanismos de atención para enfocarse en regiones importantes de la imagen durante el proceso de segmentación. Esto ayuda al modelo a priorizar la información relevante y mejorar la precisión de la segmentación.
- **Entrenamiento supervisado:** SAM se entrena utilizando datos etiquetados, donde se proporciona a la red imágenes de entrada junto con las máscaras de segmentación correspondientes. Durante el entrenamiento, el modelo ajusta sus pesos para minimizar la discrepancia entre las predicciones y las etiquetas verdaderas.
- **Optimización y regularización:** Durante el entrenamiento, SAM utiliza técnicas de optimización y regularización para evitar el sobreajuste y mejorar la generalización del modelo. Esto puede incluir el uso de funciones de pérdida específicas para la segmentación semántica, como la pérdida de entropía cruzada, y técnicas de regularización como la disminución de la tasa de aprendizaje y la eliminación aleatoria [35].



Figura 5: Ejemplo aplicación SAM.

6.8.2. UNET

El modelo U-Net es una arquitectura de red neuronal convolucional (CNN) diseñada específicamente para la segmentación de imágenes, es decir, para dividir una imagen en diferentes regiones o clases. Fue propuesta por Olaf Ronneberger, Philipp Fischer y Thomas Brox en 2015, y desde entonces se ha convertido en una de las arquitecturas más populares para la segmentación semántica debido a su efectividad y eficiencia. La estructura del modelo U-Net se asemeja a la letra "U", de ahí su nombre. Consiste en dos partes principales: el codificador (downsampling path) y el decodificador (upsampling path). Aquí está una explicación detallada de cada parte:

- Codificador (downsampling path):
 - El codificador está compuesto por una serie de capas convolucionales y de pooling que se utilizan para extraer características de la imagen de entrada y reducir su resolución espacial.
 - Cada capa convolucional se encarga de detectar características de diferentes niveles de abstracción en la imagen.
 - Después de cada capa convolucional, se suele aplicar una capa de activación (como ReLU) para introducir no linealidad en la red.
 - Entre las capas convolucionales, se realiza el muestreo espacial (downsampling) mediante capas de pooling, como MaxPooling, que reducen la resolución de la imagen pero mantienen las características importantes.
- Decodificador (upsampling path):
 - El decodificador toma las características de nivel más profundo del codificador y las utiliza para generar una salida de alta resolución que coincida con las dimensiones de la imagen original.
 - Consiste en una serie de capas de convolución transpuesta (también conocidas como deconvolución) y concatenaciones de características de la parte del codificador para realizar la upsampling de la imagen.
 - Cada capa de convolución transpuesta aumenta la resolución espacial de la imagen y, al mismo tiempo, reduce el número de canales de características.
 - Al igual que en el codificador, después de cada capa de convolución transpuesta, se suele aplicar una capa de activación.
- Conexiones laterales:
 - Para mejorar la precisión y la localización de las predicciones, U-Net utiliza conexiones laterales (skip connections) que conectan las capas de la parte del codificador con las capas correspondientes en el decodificador.
 - Estas conexiones permiten que la información detallada se transmita directamente desde las etapas de baja resolución a las etapas de alta resolución del decodificador, ayudando así a preservar los detalles finos de la imagen [36].



Figura 6: Ejemplo aplicación UNET.

6.8.3. YOLO

YOLO, que significa "You Only Look Once" (Solo Mira una Vez), es un popular modelo de detección de objetos en imágenes que se destaca por su eficiencia y precisión. Fue desarrollado por Joseph Redmon y Santosh Divvala en la Universidad de Washington. La principal característica de YOLO es que puede detectar múltiples objetos en una sola pasada a través de la imagen, a diferencia de los enfoques tradicionales que requieren múltiples pasadas. Esto hace que YOLO sea extremadamente rápido, lo que lo hace ideal para aplicaciones en tiempo real. El funcionamiento básico del modelo YOLO se basa en:

- División de la imagen: YOLO divide la imagen de entrada en una cuadrícula, generalmente de tamaño 7x7 o 9x9. Cada celda de la cuadrícula es responsable de predecir ciertos cuadros delimitadores (bounding boxes) y las probabilidades asociadas con los objetos dentro de esa celda.
- Predicción de cuadros delimitadores y clases: Para cada celda de la cuadrícula, YOLO predice un número fijo de cuadros delimitadores. Cada cuadro delimitador está compuesto por un conjunto de coordenadas (x, y, ancho, alto), que representan la posición y el tamaño del cuadro delimitador, respectivamente. Además, YOLO predice las probabilidades de clase para cada cuadro delimitador, lo que indica la probabilidad de que el objeto detectado pertenezca a una clase particular.
- Predicción de la confianza: YOLO también predice la confianza de cada cuadro delimitador, que refleja la certeza de que el cuadro delimitador contiene un objeto y la precisión de la predicción.
- Supresión de no máximos (NMS): Después de que se hacen todas las predicciones, YOLO utiliza una técnica llamada supresión de no máximos para eliminar cuadros delimitadores redundantes y seleccionar solo los cuadros delimitadores más confiables.
- Salida final: La salida final del modelo es una lista de cuadros delimitadores junto con las clases predichas y las probabilidades asociadas [37].




Figura 7: Ejemplo aplicación YOLO.

Por otro lado, para el reconocimiento facial con el modelo IA se consideraron las alternativas expuestas en el marco teórico para aplicaciones Deep Learning y de Redes neuronales.

7. Solución propuesta

Se buscaron generar alternativas fundamentadas en la inteligencia artificial y el Aprendizaje profundo para realizar el reconocimiento de los bovinos sin la necesidad de seguir usando procesos invasivos para así, producir una solución innovadora para la identificación de los bovinos con la cual, sea posible atacar tanto el problema de producir mejores condiciones para que las vacas tengan una mejor calidad de vida y minimizar los daños realizados a las mismas, como también reforzar el tema de la seguridad a través de un modelo que confronte las muestras de un bovino con las presentes en su base de datos para conocer su pertenencia al grupo de vacas registradas con una alta precisión.

7.1. Descripción general de la solución




Figura 8: Diagrama de bloques.

La secuencia de procesos comienza con una cámara que representa el sistema de hardware para la adquisición de las muestras posteriormente almacenadas en el conjunto de datos, que comprende una variedad de imágenes fotográficas que representan diversas clases de vacas presentes en la zona de estudio. Esta selección diversa se realiza para asegurar una base de datos completa y representativa de las poblaciones de vacunos en la región. Luego de esto, es posible crear la base de datos con las muestras analizadas basada en la diferenciación tanto de los bovinos con el entorno como la de cada bovino con los demás ejemplares distinguiendo cada una de sus características como color o manchas presentes en el rostro, tamaño de su cráneo, características del rostro, su fisionomía, entre otros. Esta diferenciación obtenida conforma la base sobre la cual se procederá a entrenar el modelo a partir de las muestras recopiladas. Los siguientes pasos se separan en dos grandes frentes. El primero se realiza a través de ejecución de DarkNet y el algoritmo preentrenado de Yolov4. El inicio abarca un bloque de preprocesa-

miento, donde a través de, en un primer punto, el uso del algoritmo Yolov4 para la detección de los objetos encontrados en las imágenes a partir de las clases disponibles, se capturan los elementos significativos demarcando, en este caso los bovinos, que ayudarán a diferenciar del entorno aquello que es o no un bovino.

Tras el preprocesamiento, el enfoque se dirige a entrenar un primer modelo que permita definir la presencia o no de bovinos en la zona de la imagen y realice la extracción de individuos donde se diferenciarán a cada uno de los bovinos que se ubican en la zona de estudio demarcando el contorno de cada bovino presente, que puede ser uno o varios, visualizando la similitud de los objetos detectados on la clase disponible, en este caso 'cow'.

El siguiente frente, a lo largo de la arquitectura del modelo en IA seleccionado del estado del arte, se emplean librerías de funciones algorítmicas y gráficas a través de Pandas, Matplotlib, Sklearn, Numpy y principalmente TensorFlow y Keras como una de las bibliotecas de Aprendizaje profundo. Durante el proceso de entrenamiento, se utilizan los datos previamente procesados para crear conjuntos de entrenamiento y validación, donde a partir de estos se forman pares de imágenes esenciales para afinar el rendimiento del modelo.

El núcleo de la operación se encuentra en el modelo de reconocimiento con redes siamesas, que recibe como entrada igualmente pares de imágenes del rostro de bovinos. Dependiendo de las características detectadas en las imágenes y aprendidas durante el entrenamiento, el modelo llevará a cabo su cálculo de proximidad de identidad. De esta manera, cuando se presente una fotografía de un bovino en particular, el sistema será capaz de asignarle la categoría apropiada, permitiendo así identificar de manera eficiente si el individuo o tipo de vaca pertenece para que el usuario logre visualizar, a través de todo este proceso como se aprecia en la Fig8, el resultado obtenido.

7.2. Modelo Conceptual




Figura 9: Diagrama de Flujo funcionamiento detección de bovinos.

El funcionamiento conceptual de la detección de bovinos se puede observar en la Fig 9 donde existen imágenes de entrada las cuales deben ser leídas por el programa, posteriormente se realiza la detección a través del modelo entrenado para detección de bovinos con la información obtenida de las imágenes. Básicamente, se realiza una estimación porcentual de la similitud entre los posibles objetos presentes detectados con la clase entrenada de 'cow'. Cabe resaltar que se trae a acolación la palabra posibles puesto que puede ocurrir que en la imagen no exista la presencia de bovinos, de este modo no es posible realizar la detección.




Figura 10: Diagrama de Flujo funcionamiento redes siamesas.

El funcionamiento conceptual de las redes siamesas se puede observar en la Fig10 donde existe un par de imágenes de entrada las cuales deben ser leídas por el programa, posteriormente se realiza la comparación a través del algoritmo basado en redes siamesas, con la información obtenida de las imágenes. Básicamente, se realiza una estimación de la distancia de similitud entre los bovinos presentes en las imágenes de entrada. Finalmente, se estima un umbral en la distancia del individuo con el otro para definir si el bovino que se desea comparar pertenece o no al respectivo agricultor.

7.3. Estándares de la solución

IEC (International Electrotechnical Commission) e ISO (International Organization for Standardization) colaboran en el desarrollo de normas internacionales para tecnologías de la información y la comunicación, a través de un comité técnico conjunto (ISO/IEC JTC 1). Uno de los comités (el SC 42) cubre todo el ecosistema de la inteligencia artificial (IA). El SC 42 ha publicado y está desarrollando algunas normas, que incluyen un marco para la gestión empresarial de analíticas en esta materia:

- ISO / IEC 19794-5: Empleado para el reconocimiento facial. Se usa para garantizar la calidad y la compatibilidad de las imágenes faciales en los documentos de viaje y otras

aplicaciones. El estándar define los formatos de datos y las propiedades fotográficas de las imágenes faciales, como la iluminación, el posicionamiento, el enfoque, el color, la expresión, etc. El estándar también especifica los atributos de imagen digital, como la resolución, el tamaño, el rango dinámico, etc., para facilitar el almacenamiento y el procesamiento de las imágenes faciales.

- ISO/IEC 27001: ISO/IEC 27001 es un estándar que establece los requisitos para un sistema de gestión de seguridad de la información (SGSI). Aunque no es específico de la IA, se utiliza para garantizar la seguridad de los datos y sistemas utilizados en proyectos de IA.
- ISO/IEC 27701: ISO/IEC 27701, es una extensión que se centra en la gestión de la privacidad de la información, lo que es especialmente relevante cuando se manejan datos personales en aplicaciones de IA.
- ISO/IEC 38500: Este estándar se centra en la gobernanza de tecnologías de la información en las organizaciones, lo que incluye la IA. Proporciona directrices para la alta dirección sobre cómo gestionar la tecnología de la información de manera efectiva, asegurando la alineación con los objetivos organizativos.
- Estándares del NIST: Los estándares del NIST incluyen varias pruebas de referencia (FRVT) que miden la precisión y la velocidad de los algoritmos en diferentes escenarios de aplicación, como la verificación 1:1, la identificación 1:N, el reconocimiento en vídeo, el efecto de las máscaras, etc. Los algoritmos se evalúan mediante el cálculo de los errores cometidos en el proceso de reconocimiento facial, como el rechazo falso (FRR) o la aceptación falsa (FAR), que dependen de la configuración del algoritmo y del tipo y calidad de las imágenes utilizadas.
- Principios Éticos de Asilomar: Estos principios fueron desarrollados en una conferencia de expertos en IA en Asilomar, California. Se centran en garantizar que la IA se utilice para el beneficio de la humanidad y se eviten posibles riesgos, como la superinteligencia sin control, la concentración de poder y la falta de consideración por el impacto social.

7.4. Condiciones de diseño, pruebas y evaluación

7.4.1. Condiciones de diseño

Respecto a las condiciones de diseño, se trabajó con las muestras obtenidas en la sede de Agrosavia en Tibaitatá se centraron principalmente en la división en dos grandes partes:

- Detección de bovinos: Esta primera parte va de la mano con el filtro para la creación de la base de datos, donde a través de la selección de imágenes donde estuvieran bovinos presentes, se hacía la detección de estos soportado en su mayoría con el modelo Yolov4 para poder entrenar en un primer punto la determinación de la existencia o no existencia de bovinos en las imágenes.
- Comparación de bovinos: La segunda parte se enfocó en calcular cual era la similitud de los bovinos presentes. Este proceso estaba soportado en el uso de las redes siamesas, para poder obtener, como se mencionó anteriormente, la distancia entre estos y la predicción

de su pertenencia al ganado registrado. Es importante resaltar que se realizó un *resize* a las imágenes debido a las aplicaciones posteriores que necesitaban un tamaño de imagen determinado para ingresar a la red.

7.4.2. Condiciones de prueba

Para las condiciones de pruebas, se tuvo en cuenta el lugar donde habían sido recolectadas las muestras, en este caso la sede de Agrosavia Tibaitatá, en un entorno donde se ubicó la cámara fija al aire libre priorizando un sitio de tránsito normal para los bovinos. Por tanto, existe una única perspectiva lo que puede no ser muy beneficioso ya que influye en la interpretación de los resultados al tener una sola vista de la vaca. Además se presentan diferentes condiciones de iluminación, y es uno de los principales factores a tomar en cuenta para procesar el material disponible y realizar las pruebas de detección y clasificación al tener que filtrar entre muestras que servían y las otras que no. Los bovinos involucrados presentan diferentes características como colores, rasgos faciales, tamaño, etc. Por otro lado, existe la posibilidad que no todas las vacas pasen todos los días a la misma hora, algunas veces pasan otros individuos que antes no habían pasado y esto dificulta la separación de muestras entre cada bovino. Con base en lo anterior, se procedieron a realizar las diferentes pruebas con el fin de resaltar los bovinos en las distintas muestras obtenidas para el desarrollo del proyecto.

7.4.3. Condiciones de evaluación

En cuanto a las condiciones de evaluación, fue principalmente enfocado hacia la matriz de confusión, la cual permitió visualizar el desempeño del algoritmo empleado permitiendo ver que tipo de aciertos y errores estaba teniendo el modelo a la hora de pasar por el proceso de aprendizaje con los datos.

Cada columna de la matriz representa el número de predicciones de cada clase, mientras que cada fila representa a las instancias en la clase real.



Figura 11: Esquema Matriz de confusión

A partir de estas 4 opciones surgen los diferentes parámetros de la matriz de confusión:

- La **Exactitud** es la cantidad de predicciones positivas que fueron correctas. Se calcula como la proporción de resultados verdaderos, tanto positivos como negativos, dividida entre el número total de casos examinados, incluyendo verdaderos positivos, falsos positivos, verdaderos negativos y falsos negativos. Su valor oscila entre 0 y 1. Entre más cercano este a 1 mejor es el funcionamiento del modelo.

$$ACC = \frac{TP + TN}{P + N} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

- La **Precisión o valor predictivo positivo (PPV)** es la dispersión del conjunto de valores obtenidos a partir de mediciones repetidas de una magnitud. Cuanto menor es la dispersión mayor la precisión. Su valor oscila entre 0 y 1. Entre más cercano este a 1 mejor es el funcionamiento del modelo. Se representa por la proporción de verdaderos positivos dividido entre todos los resultados positivos (tanto verdaderos positivos, como falsos positivos).

$$PPV = \frac{TP}{TP + FP} \quad (2)$$

- El **valor predictivo negativo (NPV)** indica la probabilidad de que un resultado negativo en la prueba sea realmente negativo en la población analizada. Su valor oscila entre 0 y 1. Entre más cercano este a 1 mejor es el funcionamiento del modelo.

$$NPV = \frac{TN}{TN + FN} \quad (3)$$

- La **Sensibilidad** también se conoce como **Tasa de Verdaderos Positivos** (True Positive Rate) ó TPR. Es la proporción de casos positivos que fueron correctamente identificadas por el algoritmo. Su valor oscila entre 0 y 1. Entre más cercano este a 1 mejor es el funcionamiento del modelo.

$$TPR = \frac{TP}{P} = \frac{TP}{TP + FN} \quad (4)$$

- La **Especificidad** es también **Tasa de Verdaderos Negativos**, (“true negative rate”) o TNR. Se trata de los casos negativos que el algoritmo ha clasificado correctamente. Su valor oscila entre 0 y 1. Entre más cercano este a 1 mejor es el funcionamiento del modelo.

$$TNR = \frac{TN}{N} = \frac{TN}{TN + FP} \quad (5)$$

- El **F1 Score** es una medida de la exactitud que puede calcularse a partir de la precisión y la sensibilidad usando la media armónica de estas. Su valor oscila entre 0 y 1. Entre más cercano este a 1 mejor es el funcionamiento del modelo.

$$F1 = 2 * \frac{PPV * TPR}{PPV + TPR} = \frac{2TP}{2TP + FP + FN} \quad (6)$$

- El **Coefficiente de correlación de Matthews** tiene en cuenta los positivos y negativos verdaderos y falsos. Se considera una medida equilibrada que se puede utilizar incluso si las clases son de tamaño muy diferentes.

$$MCC = \frac{TP * TN - FP * FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \quad (7)$$

- La curva ROC (Receiver Operating Characteristic) es una herramienta gráfica utilizada para evaluar el rendimiento de un clasificador binario. Esta curva representa la tasa de verdaderos positivos (TPR) frente a la tasa de falsos positivos (FPR) para diferentes umbrales de clasificación.

El eje x de la curva ROC representa la tasa de falsos positivos (FPR), que es la proporción de instancias negativas que se clasifican incorrectamente como positivas. El eje y representa la tasa de verdaderos positivos (TPR), que es la proporción de instancias positivas que se clasifican correctamente como positivas, también conocida como sensibilidad.

Idealmente, se desea que la curva ROC esté lo más cerca posible del rincón superior izquierdo del gráfico, lo que indicaría una alta sensibilidad (TPR) y una baja tasa de falsos positivos (FPR). Esto significaría que el clasificador es capaz de distinguir perfectamente entre las clases positivas y negativas.

Estos parámetros representaron las principales condiciones de evaluación para observar el desempeño del algoritmo.

8. Diseño

8.1. Descripción general del diseño

Las muestras recopiladas por Agrosavia, institución reconocida por su experiencia en investigación agropecuaria, junto a una metodología de recolección y etiquetado, proporcionaron un conjunto de datos confiable y diverso para la implementación de redes siamesas. Estas redes, reconocidas por su capacidad para comparar y contrastar similitudes entre dos imágenes, fueron fundamentales para el análisis detallado de las características faciales de los bovinos en el contexto particular de la sabana de Bogotá. La integración de Darknet, un framework de código abierto, escrito en lenguaje de programación C y CUDA, que se utiliza principalmente para el desarrollo de aplicaciones relacionadas con el aprendizaje profundo, especialmente para la detección de objetos, reconocimiento de imágenes y segmentación semántica; en conjunto con redes siamesas ayuda no solo una mayor precisión en el reconocimiento facial del ganado, sino también una herramienta más robusta y adaptable a las condiciones variables de este entorno específico. Este enfoque técnico combinado se alinea para proporcionar una solución eficiente en la identificación y seguimiento del ganado de la región.

8.2. Diagramas de bloques

A continuación se muestra la arquitectura de la red Yolov4 en un modelo realizado en Darknet:




Figura 12: Arquitectura de red basada en Yolov4.

Se ha decidido realizar una división en cuanto a la naturaleza de la red siamesa en dos bloques:




Figura 13: Arquitectura de la Red Neuronal Siamesa.

8.3. Descripción de los bloques

8.3.1. Arquitectura de la red para detección implementada

En la Fig 12 se observa un detector típico de objetos consta de distintas secciones, como la entrada, la columna posterior, el cuello y la cabeza. La columna posterior de YOLOv4 se encuentra pre-entrenada en ImageNet y se emplea para predecir clases y delimitar cajas de objetos. Esta columna posterior puede ser de diferentes modelos, como VGG, ResNet, ResNeXt o DenseNet. El cuello del detector se utiliza para recopilar mapas de características de diversas etapas, normalmente integrando múltiples rutas ascendentes y descendentes. La cabeza del detector es la encargada de realizar las detecciones y clasificaciones finales de objetos.

8.3.2. Arquitectura de las redes siamesas implementadas

Durante el marco teórico, se ha definido el concepto de red neuronal siamesa. Se analizaron distintos modelos del estado del arte para la posterior aplicación con la base de datos. El algoritmo basado en IA ha sido diseñado con el lenguaje Python, utilizando librerías open source como Keras, TensorFlow, Pandas, Numpy, entre otras. A continuación se explican los dos bloques que componen la red siamesa.

8.3.2.1. Bloque 1: Extracción de Características La etapa de caracterización juega un papel crucial en el proceso de concepción de una red siamesa. Durante esta fase, se llevan a cabo múltiples inferencias mediante las capas convolucionales hasta alcanzar una capa final conocida como cuello de botella o bottleneck, que luego se emplea como entrada para el bloque II. El bloque de extracción de características se destaca como el componente más robusto y extenso entre los dos. Para generar los diversos bottlenecks, las imágenes ingresadas al bloque pasan por diversas capas de aprendizaje profundo que incluyen convoluciones, max-pooling, entre otras. Aunque estas capas son más livianas en comparación con las capas totalmente conectadas, se requiere un gran número de ellas para la extracción de características antes de alcanzar el cuello de botella. Esto implica un esfuerzo considerable en el diseño y la implementación de una arquitectura que garantice los mejores resultados.

8.3.2.2. Bloque 2: Clasificación El bloque de clasificación tiene la responsabilidad de ejecutar las acciones requeridas para discernir si dos imágenes diferentes muestran al mismo bovino o no. El enfoque de aprendizaje utilizado en este proyecto, que se basa en redes de neuronas, es el de clasificación binaria, una modalidad que se encuentra dentro del conjunto de técnicas de aprendizaje supervisado. Por consiguiente, para llevar a cabo este proceso de entrenamiento, se requiere de un conjunto de etiquetas o "labels" binario que permitan al algoritmo diferenciar entre imágenes que representan a un bovino y aquellas que representan a bovinos diferentes para posteriormente calcular la distancia entre las imágenes con el modelo entrenado. La estructura fundamental consistió en:

- Input: Un array o lista que contiene la información de las características, obtenida al calcular la diferencia absoluta entre las salidas del bloque 1 o bottlenecks.

- Output: Un array o lista que representa la predicción de similitud entre las dos imágenes donde si pertenecen a la misma vaca, es más cercana a 1 en comparación a que fueran diferentes bovinos.

8.4. Diagramas de flujo

8.4.1. Base de datos

El montaje de un sistema de hardware en las instalaciones de Agrosavia Tibaitatá que permitiera la adquisición de las muestras era sumamente importante, debido a que a partir de estas se obtenía el material para trabajar el proyecto.

De este modo, la cámara se ubicó en un lugar donde los bovinos pasaran de manera frecuente. Se mantuvo grabando y tomando fotografías durante 2 meses en el rango de 4am hasta 8pm dividiendo internamente las fotografías y los vídeos en carpetas separadas según el día y la hora pertinente.

Posteriormente se realizó la separación del material:




Figura 14: Diagrama de Flujo Filtrado de material

Como se observa en la Fig 14, los dos puntos importantes para la selección del material fue

que existiera algún bovino presente y además que fuera posible observar el rostro del bovino. Si no cumplía con estas dos condiciones, se descartaba y no se empleaba para el proyecto. Por otro lado, al cumplir ambas condiciones, se etiquetaba la fotografía con un número determinado y en caso de no haber sido registrado el bovino en la tabla Excel dispuesta (Anexo A.1), se realizaba este registro. A continuación se muestran algunos ejemplos de imágenes aceptadas y descartadas para el proyecto.

Primero se logra apreciar en las imágenes anteriores defectos como rostros de los bovinos tapados, vista borrosa durante la noche e incluso vistas donde no hay presencia de estos, lo cual no permitía un correcto desarrollo:



Figura 15: Ejemplo de imágenes descartadas.

Luego, las siguientes imágenes muestran una buena iluminación donde se puede ver claramente el rostro del bovino en los diferentes casos, ya sea el único presente o con algún otro:




Figura 16: Ejemplo de imágenes aceptadas.

Finalmente se lograron identificar 78 distintos bovinos en la zona que se registraron. No obstante, la cantidad de fotos no era igual para todos los individuos, dado que algunos ejemplares presentaban muy pocas muestras, lo cual no resultaba significativo para el desarrollo del

proyecto. Se mantuvieron aquellos individuos que tuvieran al menos 15 muestras adecuadas para trabajar, lo que redujo a 27 el número de bovinos.

Por tanto, para la creación de la base de datos o dataset (Anexo A.2), se dividió la carpeta principal en 3 subcarpetas llamadas Entrenamiento, Validación y Test. Dentro de cada subcarpeta existían 27 subcarpetas donde cada carpeta representaba un bovino específico.



Figura 17: Composición general del Dataset




Figura 18: Composición general de las 3 subcarpetas

La repartición de imágenes fue manteniendo una proporción de 3 a 1: Por cada 3 imágenes de entrenamiento una imagen de validación y dejando las restantes para Test teniendo en cuenta la importancia de otorgar la mayoría de muestras al entrenamiento. En la siguiente tabla se muestra la distribución final del Dataset para cada bovino:

Tabla 1: Distribución de imágenes del dataset

Bovino	Entrenamiento	Validación	Test
1	9	3	3
7	9	3	2
8	9	3	1
11	15	5	4
12	9	3	1
18	21	7	4
19	12	4	1
21	27	9	3
27	51	17	9
29	9	3	3
33	24	8	2
34	12	4	3
35	9	3	1
36	24	8	2
38	15	5	4
43	42	14	5
49	15	5	1
50	18	6	2
55	15	5	3
56	9	3	3
57	12	4	4
62	9	3	2
64	24	8	1
70	30	10	3
72	33	11	4
75	24	8	2
78	12	4	3

8.4.2. Detección de bovinos

En primera instancia se recaudaron 400 fotografías aleatorias pertenecientes al entrenamiento del Dataset con las que se procedió a trabajar en Darknet. Para el uso de DarkNet, se empleó el servidor Cratos dispuesto por la universidad a través de la asignación de un usuario. De esta manera, se siguió el siguiente proceso:




Figura 19: Diagrama de Flujo etiquetado para detección de bovinos

Como se aprecia en la Fig 19, el proceso comienza subiendo las 400 imágenes a la carpeta seleccionada en el servidor y desde esta misma carpeta abrir la interfaz de DarkMark. De esta manera, se procede a realizar el etiquetado de los bovinos presentes en cada una de las imágenes utilizadas, verificando que se demarque por completo el contorno del bovino o de los bovinos cada uno por separado.



Figura 20: Ejemplo de imágenes etiquetadas.

Luego, se repetía el etiquetado hasta llegar a la imagen 400 teniendo en cuenta la barra roja a la derecha de las imágenes anteriores, donde finalmente se creaban los archivos DarkNet aplicando la mitad del tamaño calculado de la red neuronal(Anexo A.3) ya que resultaba muy grande y no se tenían los recursos necesarios, por lo que se sacrificó definición por recursos, posteriormente se entrenaba el modelo para su aplicación.




Figura 21: Creación de archivos Darknet

8.4.3. Identificación de bovinos.




Figura 22: Diagrama de Flujo Algoritmo Redes siamesas.

A partir de la Fig 22, se realizó el código para el modelo de redes siamesas (Anexo A.4). Como primer punto, se realizan las importaciones de las librerías como TensorFlow, Keras entre otras. Luego se que construye la arquitectura de la red siamesa. Esta red toma dos imágenes como entrada en capas diferentes y produce un vector de características para cada una. Después, a través del cálculo de la distancia L1 entre los vectores se realiza una comparación entre ambas imágenes para crear la capa de clasificación final. Luego, se crea el modelo siamesa definiendo las entradas y las salidas a la red.

Posteriormente, se cargan las imágenes de entrenamiento del Dataset *traindir* con sus respectivas etiquetas donde se crean los pares de las imágenes de entrenamiento. Con estos recursos se entrena la red siamesa. En una red siamesa, se desea que las imágenes similares tengan vectores de características similares y viceversa. Aquí es posible gráficar las métricas de *Accuracy* y *Loss* del entrenamiento. Este modelo se guardó el modelo entrenado en un archivo.h, por tanto, es el que se empleó para las pruebas con las imágenes de Test.

8.5. Criterios de selección

Con base en el apartado 6.8, se seleccionó YOLO para realizar la detección de bovinos presentes principalmente por las siguientes razones:

- **Eficiencia:** YOLO es extremadamente rápido en comparación con otros modelos de detección de objetos, ya que realiza todas las predicciones en una sola pasada a través de la imagen.
- **Precisión:** A pesar de su eficiencia, YOLO logra una precisión bastante alta en la detección de objetos, lo que lo hace adecuado para una variedad de aplicaciones.
- **Capacidad de detección de múltiples clases:** YOLO puede detectar múltiples clases de objetos en una sola imagen, lo que lo hace versátil y útil para una amplia gama de aplicaciones.

A partir de esto, se empleó también Darknet, el cual proporciona una infraestructura flexible y potente para construir y entrenar redes neuronales convolucionales (CNN) para una variedad de tareas de visión por computadora. Es conocido principalmente por ser el marco en el que se desarrolló y entrenó YOLO.

Por otro lado, para el reconocimiento facial en bovinos, se analizaron las alternativas presentadas en el estado del arte y se determinó a las redes siamesas como la mejor opción. Utilizar redes siamesas para la identificación facial tiene varias ventajas sustanciales que se derivan de su arquitectura única y su capacidad para capturar y comparar características específicas entre dos imágenes. Algunas características se basan en:

- **Robustez frente a la variabilidad:** Los rostros pueden variar enormemente debido a diferentes condiciones de iluminación, expresiones faciales, poses y oclusiones. Las redes siamesas son robustas frente a esta variabilidad porque aprenden a identificar características invariantes que son consistentes en diferentes condiciones. Esto significa que la red puede reconocer un rostro incluso si está parcialmente oscurecido, girado o con una expresión diferente.
- **Comparación directa de características:** La arquitectura siamesa permite comparar directamente las características de dos imágenes faciales. Esto es esencial para la identificación facial, ya que implica la comparación de la similitud entre un rostro de consulta y una base de datos de rostros conocidos. Al comparar directamente las características de los dos rostros, la red puede calcular una medida de similitud o distancia entre ellos, lo que facilita la identificación del rostro.
- **Eficiencia computacional:** Las redes siamesas pueden ser más eficientes computacionalmente que otros enfoques más complejos de identificación facial. Debido a su arquitectura paralela y compartida, la red solo necesita realizar una sola pasada hacia adelante para calcular las características de dos imágenes faciales, lo que la hace rápida y eficiente para aplicaciones en tiempo real.

9. Pruebas y resultados

Durante el desarrollo del proyecto, se llevaron a cabo una serie de pruebas con el objetivo de validar la viabilidad y eficacia de los diversos métodos considerados para su implementación. Las pruebas fueron registradas en el protocolo de pruebas(Anexo A.5). No obstante, a continuación, se destacan las pruebas más significativas que se realizaron en diferentes etapas del proceso de desarrollo:

9.1. Pruebas iniciales Redes Siamesas

- Una primera prueba fue *Prueba de redes siamesas genéricas con 2 imágenes diferentes a través de Google Colab*, en el que se empleaban dos imágenes diferentes, en este caso una gallina y una vaca, para que con una pequeña red siamesa codificada en lenguaje Python se diera una aproximación al funcionamiento de estas:



Figura 23: Prueba 1 con Redes siamesas genéricas.

- Posteriormente, se realizó una prueba similar *Prueba de redes siamesas genéricas con 2 imágenes similares a través de Google Colab* pero esta vez utilizando dos imágenes de vacas similares para comparar los resultados de las distancias entre los vectores de características:




Figura 24: Prueba 2 con Redes siamesas genéricas.

Como se aprecia en las dos figuras anteriores, la distancia entre las imágenes es menor, aproximadamente 10 veces en este caso, entre las 2 vacas en comparación con la vaca y la gallina, lo que indica que los vectores de características entre ambas imágenes son más cercanos en la prueba 2.

9.2. Pruebas y resultado detección de bovinos

- La siguiente prueba que se logró realizar es *Segmentación con umbral a través de Google Colab*, donde se utilizó una imagen de una vaca ubicada en Agrosavia y se emplearon operaciones morfológicas y de procesamiento de imágenes a través de un código en lenguaje Python con el fin de separar el contorno de esta con el fondo exterior:



Figura 25: Prueba 4, Imagen de vaca original.




Figura 26: Prueba 4, Imagen de vaca umbralizada.

En la Fig 26 se logra apreciar con un tono, en su mayoría negro, al bovino presente. Sin embargo, esta umbralización aún sigue juntando regiones que no pertenecen al bovino como la sombra o las paredes del fondo.



Figura 27: Prueba 4, Imagen de vaca bordeada.

En la anterior imagen, el objetivo era bordear el contorno de la vaca para diferenciarla del resto de objetos presentes. No obstante, no se logró un buen resultado ya que no lo definía correctamente al no distinguir lo que formaba parte de la vaca y lo que no.

- La siguiente prueba se basó en *Detección de objetos con Yolov4 a través de Darknet con imágenes originales*, donde se utilizaron diferentes muestras de prueba de las recolectadas en la sede de Agrosavia para observar el funcionamiento del modelo Yolov4 el cual posee clases entrenadas predeterminadas, utilizando el entorno de Darknet a través del servidor Cratos. Esta prueba de etiquetado automático arrojó para cada imagen un archivo txt con los números correspondientes de las clases reconocidas y sus posiciones y una imagen etiquetada con los cuadros de colores que, en este caso, no correspondía con lo presente en la imagen catalogando principalmente a vacas como personas.

Posteriormente, se rotaron las imágenes 90 grados a la izquierda para que fuera posible analizarlas de manera vertical. Esto produjo un mejor resultado dado que, a pesar de aún no reconocer de manera completamente correcta a los bovinos, los catalogaba como caballos o zebras e incluso, en algunos casos, si se reconocía como vacas, algo más cercano a la realidad. A continuación se muestran algunos resultados de esta prueba:



Figura 28: Prueba 6, Imágenes obtenidas de la detección con el modelo Yolov4.

- Una siguiente prueba consistió en *Prueba de etiquetado rápido a través de un script en Python*. Igualmente utilizando el entorno de Darknet a través del servidor Cratos, visualizando los resultados de la prueba anterior, se realizó un Script(Anexo A.6) que pudiera modificar las etiquetas halladas para únicamente mantener las "cow" que son las de interés y cambiando o despreciando las otras según fuera necesario en los archivos txt generados, donde se presentan el número de las etiquetas y la ubicación estas al cargar las imágenes a DarkNet. No obstante, no arrojó un buen resultado dado que, al implementarlo, cambiaba el número de la etiqueta pero no de manera correcta y se alteraban y corrompían las imágenes:




Figura 29: Prueba 7, Imágenes corrompidas por Script.

- En este punto, se procedió a realizar la prueba *Detección de objetos con modelo entrenado propio a través de Darknet con imágenes rotadas* utilizando las imágenes etiquetadas con el procedimiento explicado en la Fig 19




Figura 30: Prueba 8, Entrenamiento del modelo creado.

Observando la Fig 30, se entrenó el modelo creado obteniendo las gráficas de Accuracy y Loss gráficas para utilizarlo en la detección de bovinos con diferentes imágenes de entrada. Como se logra apreciar, a medida que se avanza en los lotes de imágenes, la pérdida disminuye y la exactitud aumenta llegando a un porcentaje de 92, el cual al estar cercano a 100 representa un buen desempeño. A continuación se muestran algunos resultados de esta prueba:



Figura 31: Prueba 8, Imágenes resultado de la detección con modelo entrenado.

Observando las anteriores imágenes, el modelo logró detectar a los bovinos presentes de una manera muy aproximada a la realidad. En el primer y último caso, presentó la demarcación del individuo o individuos con un porcentaje de estimación refiriéndose a que tan probable es que sea un bovino, mientras que en la segunda imagen, al no haber

bovinos presentes, lo correcto como ocurre es que no hubiera demarcado algún sector de la imagen.

9.3. Pruebas de entrenamiento del Algoritmo basado en redes siamesas

Para esta sección, con el algoritmo completo se procedió a realizar las pruebas de entrenamiento teniendo en cuenta la cantidad de imágenes a utilizar y el número de epochs para este proceso.

- Como primera prueba, se deseaban utilizar todas las imágenes disponibles en el dataset de entrenamiento para realizarlo a través del Servidor cratos. En total eran 27 bovinos identificados con aproximadamente de 10 a 15 fotografías por cada uno. Se configuraron 15 epochs o iteraciones de todos los datos de entrenamiento del dataset en un ciclo para entrenar el modelo. No obstante, al existir esta cantidad de imágenes no se tenían disponibles los recursos computacionales para procesarlas durante el entrenamiento, además que se debían generar pares de imágenes al ser redes siamesas y se generarían demasiadas combinaciones, por lo que el sistema arrojó error por memoria insuficiente. A continuación, se muestra el mensaje de salida obtenido:
- Posteriormente, se redujo el número de imágenes a tratar a 15 individuos que representaran diferentes características de los bovinos existentes, teniendo en cuenta la diversidad que se presentaba en la zona. Con esto, se definieron los nuevos datos para realizar el entrenamiento. Sin embargo, al acabar este proceso, se observó que hubo un sobreentrenamiento dado que el codo en la exactitud llegó a 1 en aproximadamente la epoch 9 y se mantuvo en ese punto durante los ciclos restantes, debido al número de epochs definido que resulto ser muy alto.
- Con base en la anterior prueba, se configuró el número de epochs en 8 manteniendo los demás parámetros iguales y se realizó de nuevo el entrenamiento. A continuación se presenta finalmente el resultado obtenido:




Figura 32: Prueba 11, Gráficas de Accuracy y Loss del entrenamiento.

Como se observa, la gráfica de Accuracy inicia creciendo rápidamente, luego de manera más lenta y finaliza muy cercana a 1 pero no se encuentra sobreentrenada al no llegar

a 1 y manteneerse así. Por otro lado, la gráfica de Loss decrece rápidamente, después la pendiente disminuye y finaliza muy cercana a 0. Como se evidencia, el desempeño en este punto es bastante bueno siguiendo las métricas establecidas.

9.4. Pruebas y resultado de Algoritmo basado en redes siamesas

Ya habiéndose entrenado el algoritmo, se realizaron distintas pruebas para verificar el funcionamiento del modelo con las imágenes proporcionadas del Dataset.

- Debido a que la red siamesa recibe dos imágenes para hacer la comparación, se realizó el código(Anexo A.7) y se llevo a cabo la *Prueba con dos imágenes pertenecientes al mismo bovino de test del dataset* donde se tomaron dos imágenes aleatorias de la misma carpeta de test de un bovino. Se esperaba que al final se mostraran las dos imágenes con la predicción de similitud entre los bovinos. Entre más cercana sea esta distancia a 1, es más probable que sea la misma vaca. A continuación se muestra el ejemplo:




Figura 33: Prueba 12, Predicción del modelo siamesa para mismos bovinos.

- Para corroborar, se realizó *Prueba con dos imágenes pertenecientes a distintos bovinos de test del dataset*. Igualmente, se tomaron dos imágenes aleatorias de carpetas distintas de test de diferentes bovinos. Se esperaba que al final se mostraran las dos imágenes con la predicción de similitud entre los bovinos. Entre más cercana sea esta distancia a 0, es más probable que sea una vaca diferente. A continuación se muestra el ejemplo:




Figura 34: Prueba 13, Predicción del modelo siamesa para bovinos distintos.




Figura 35: Prueba 13, Predicción del modelo siamesa para bovinos similares.

Comparando los tres casos, en este punto se obtuvo un buen desempeño del modelo. La distancia más cercana a 0 se presenta en la Fig 34 donde los bovinos son distintos a simple vista, por lo que la predicción definida como bovinos distintos. La Fig 35 presenta bovinos que pueden verse similares, entonces la predicción, a pesar de ser un poco más alejada a 0 que el caso anterior, sigue siendo prácticamente cero, otorgando la categoría de bovinos distintos. Por otro lado, la Fig 33 presenta dos imágenes de un mismo bovino, por consiguiente la distancia que separa los dos casos anteriores y este es muy grande, además la predicción es mucho más cercana a 1 y en este punto se cataloga como mismo bovino.

Con esto, a partir de la evaluación realizada en el apartado 10, se modificó el código anterior(Anexo A.7) del cual se muestran algunos de los resultados para diferentes casos de identificación en los bovinos al comparar dos imágenes pertenecientes a la carpeta Test del Dataset:




Figura 36: Caso 1.




Figura 37: Caso 2.




Figura 38: Caso 3.




Figura 39: Caso 4.




Figura 40: Caso 5.




Figura 41: Caso 6.

Figura 42: Imágenes resultado de la comparación entre bovinos a través de Redes Siamesas.

Evidenciando los casos mostrados anteriormente, a partir del umbral definido se afirma si las imágenes corresponden o no a un mismo bovino. En los primeros tres casos, de las figuras 36, 37, 38 se ingresaron dos imágenes diferentes pertenecientes a un mismo bovino al modelo siamesa y efectivamente el resultado arrojó que se trata de un mismo ejemplar. Por otro lado, en el caso de la Fig 40, se ingresaron al modelo dos imágenes pertenecientes a bovinos diferentes y se muestra que no corresponden a un mismo bovino. No obstante, existieron casos como los mostrados en las figuras 39 y 41 donde se ingresaban imágenes de un mismo bovino y arrojaba no correspondía, mientras que si se ingresaban imágenes de bovinos diferentes, arrojaba que eran el mismo bovino. De este modo, se procedió igualmente a realizar la evaluación.

10. Evaluación del proyecto

Para la evaluación del proyecto, se realizaron diferentes pruebas enfocadas en la matriz de confusión para evaluar el desempeño del algoritmo de redes siamesas. Dado que se trata de un modelo predictivo basado en una clasificación binaria, el resultado numérico al pasar por el algoritmo las imágenes que se desean analizar debe estar entre 0 y 1. Entre mayor sea la cercanía de los vectores de características de las imágenes, en otras palabras entre menor sea la distancia euclidiana, la predicción que se trate de un mismo bovino será cercana a 1. El caso contrario, entre mayor sea la distancia euclidiana, el resultado de la predicción será cercano a 0. Por tanto, es necesario tener como referencia un umbral determinado para, dentro de este rango de valores, definir si se trata de un mismo bovino o no dejando un valor entero de 0 o 1 dependiendo si es mayor o menor al umbral.

Como primera evaluación, se definió un umbral de 0.003 tomando en cuenta las pruebas de las Fig 33, 34 y 35 con el fin de dar un primer vistazo al resultado de una posible matriz de confusión. Para esto se empleó el código (Anexo A.8) tomando las imágenes del conjunto de validación del dataset y formando pares de imágenes asignando las etiquetas reales e importando el modelo para las predicciones. El resultado se muestra a continuación:

Tabla 2: Matriz de confusión con umbral 0.003

2476	795
78	221

Teniendo como referencia la Fig 11, la cantidad de verdaderos positivos y verdaderos negativos es alta, lo cual es bueno al momento de la predicción. No obstante, en los falsos positivos se ve reflejada una cifra muy alta que para la aplicación del proyecto no es lo mejor, dado que para un ganadero representa una menor gravedad no tomar como suyo un bovino que si es a tomar como suyo un bovino que no le pertenece. Considerando lo anterior, el umbral de 0.003 es bajo al tener un valor significativo de falsos positivos.

De esta manera, se deseaba evaluar para una mayor cantidad de casos el valor de la predicción con el fin de tener una mejor referencia. Para esto, se realizó el código (Anexo A.9) que importaba el modelo de redes siamesas y creaba pares de imágenes con el conjunto de validación y por cada uno arrojaba el valor de la predicción. A continuación se muestran algunos resultados obtenidos:

```

Comparando Dataset/ValiPrueba/Bovino33/52.08[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino33/51.59[M][000][0]_33.jpg:
Valor de la predicción: [[0.02766865]]

Comparando Dataset/ValiPrueba/Bovino33/52.08[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.30[M][000][0]_21.jpg:
Valor de la predicción: [[0.00028871]]

Comparando Dataset/ValiPrueba/Bovino33/52.08[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.36[M][000][0]_21.jpg:
Valor de la predicción: [[0.00023177]]

Comparando Dataset/ValiPrueba/Bovino33/52.08[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.39[M][000][0]_21.jpg:
Valor de la predicción: [[0.00086966]]

Comparando Dataset/ValiPrueba/Bovino33/52.08[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.19[M][000][0]_21.jpg:
Valor de la predicción: [[1.764121e-06]]

Comparando Dataset/ValiPrueba/Bovino33/52.08[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.13[M][000][0]_21.jpg:
Valor de la predicción: [[0.00012511]]

Comparando Dataset/ValiPrueba/Bovino33/52.08[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.03[M][000][0]_21.jpg:
Valor de la predicción: [[0.0010623]]

Comparando Dataset/ValiPrueba/Bovino33/52.08[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.10[M][000][0]_21.jpg:
Valor de la predicción: [[7.220707e-05]]

Comparando Dataset/ValiPrueba/Bovino33/52.08[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.00[M][000][0]_21.jpg:
Valor de la predicción: [[1.33360145e-05]]

Comparando Dataset/ValiPrueba/Bovino33/52.08[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.06[M][000][0]_21.jpg:
Valor de la predicción: [[1.7251405e-05]]

Comparando Dataset/ValiPrueba/Bovino33/51.59[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.30[M][000][0]_21.jpg:
Valor de la predicción: [[2.8183382e-05]]

Comparando Dataset/ValiPrueba/Bovino33/51.59[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.36[M][000][0]_21.jpg:
Valor de la predicción: [[8.379426e-07]]

Comparando Dataset/ValiPrueba/Bovino33/51.59[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.39[M][000][0]_21.jpg:
Valor de la predicción: [[2.379813e-05]]

Comparando Dataset/ValiPrueba/Bovino33/51.59[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.19[M][000][0]_21.jpg:
Valor de la predicción: [[1.4610097e-07]]

Comparando Dataset/ValiPrueba/Bovino33/51.59[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.13[M][000][0]_21.jpg:
Valor de la predicción: [[1.0446525e-05]]

Comparando Dataset/ValiPrueba/Bovino33/51.59[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.03[M][000][0]_21.jpg:
Valor de la predicción: [[4.0318082e-05]]

Comparando Dataset/ValiPrueba/Bovino33/51.59[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.10[M][000][0]_21.jpg:
Valor de la predicción: [[1.01458e-06]]

Comparando Dataset/ValiPrueba/Bovino33/51.59[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.00[M][000][0]_21.jpg:
Valor de la predicción: [[1.1412958e-07]]

Comparando Dataset/ValiPrueba/Bovino33/51.59[M][000][0]_33.jpg y Dataset/ValiPrueba/Bovino21/49.06[M][000][0]_21.jpg:
Valor de la predicción: [[1.0153102e-07]]

Comparando Dataset/ValiPrueba/Bovino21/49.30[M][000][0]_21.jpg y Dataset/ValiPrueba/Bovino21/49.36[M][000][0]_21.jpg:
Valor de la predicción: [[0.07861906]]

Comparando Dataset/ValiPrueba/Bovino21/49.30[M][000][0]_21.jpg y Dataset/ValiPrueba/Bovino21/49.39[M][000][0]_21.jpg:
Valor de la predicción: [[0.99977463]]

```

Figura 43: Valores de predicciones con 2 imágenes aleatorias.

Como se observa en la Fig 43, en el caso donde son imágenes de carpetas diferentes, el valor de la predicción es muy pequeño, prácticamente que es 0. Sin embargo, cabe resaltar los dos últimos casos: Son imágenes que pertenecen a un mismo bovino pero la primera predijo un valor de 0.0786 y la siguiente de 0.99977. A partir de esto se deduce que, a pesar de en su mayoría mostrar un correcto funcionamiento, existen algunos casos que muestran un rendimiento no perfecto.

```

Comparando imagen f1ja 'Dataset/Val1Prueba/Bovino38/24.15[M][000][0]_38.jpg' con 'Dataset/Val1Prueba/Bovino12/42.50[M][000][0]_12.jpg':
Valor de la predicción: [[0.00289619]]
Comparando imagen f1ja 'Dataset/Val1Prueba/Bovino38/24.15[M][000][0]_38.jpg' con 'Dataset/Val1Prueba/Bovino38/24.15[M][000][0]_38.jpg':
Valor de la predicción: [[0.64496344]]
Comparando imagen f1ja 'Dataset/Val1Prueba/Bovino38/24.15[M][000][0]_38.jpg' con 'Dataset/Val1Prueba/Bovino38/24.06[M][000][0]_38.jpg':
Valor de la predicción: [[0.9336928]]
Comparando imagen f1ja 'Dataset/Val1Prueba/Bovino38/24.15[M][000][0]_38.jpg' con 'Dataset/Val1Prueba/Bovino38/24.18[M][000][0]_38.jpg':
Valor de la predicción: [[0.32846123]]
Comparando imagen f1ja 'Dataset/Val1Prueba/Bovino38/24.15[M][000][0]_38.jpg' con 'Dataset/Val1Prueba/Bovino38/24.09[M][000][0]_38.jpg':
Valor de la predicción: [[0.8221302]]
Comparando imagen f1ja 'Dataset/Val1Prueba/Bovino38/24.15[M][000][0]_38.jpg' con 'Dataset/Val1Prueba/Bovino38/24.12[M][000][0]_38.jpg':
Valor de la predicción: [[0.74037236]]
Comparando imagen f1ja 'Dataset/Val1Prueba/Bovino38/24.15[M][000][0]_38.jpg' con 'Dataset/Val1Prueba/Bovino29/13.23[M][000][0]_29.jpg':
Valor de la predicción: [[4.4171802e-07]]
Comparando imagen f1ja 'Dataset/Val1Prueba/Bovino38/24.15[M][000][0]_38.jpg' con 'Dataset/Val1Prueba/Bovino29/13.29[M][000][0]_29.jpg':
Valor de la predicción: [[1.2333425e-08]]
Comparando imagen f1ja 'Dataset/Val1Prueba/Bovino38/24.15[M][000][0]_38.jpg' con 'Dataset/Val1Prueba/Bovino29/13.20[M][000][0]_29.jpg':
Valor de la predicción: [[1.0576863e-07]]
Comparando imagen f1ja 'Dataset/Val1Prueba/Bovino38/24.15[M][000][0]_38.jpg' con 'Dataset/Val1Prueba/Bovino18/54.19[M][000][0]_18.jpg':
Valor de la predicción: [[0.13851342]]
Comparando imagen f1ja 'Dataset/Val1Prueba/Bovino38/24.15[M][000][0]_38.jpg' con 'Dataset/Val1Prueba/Bovino18/54.13[M][000][0]_18.jpg':
Valor de la predicción: [[0.17564369]]
Comparando imagen f1ja 'Dataset/Val1Prueba/Bovino38/24.15[M][000][0]_38.jpg' con 'Dataset/Val1Prueba/Bovino18/55.43[M][000][0]_18.jpg':
Valor de la predicción: [[0.01018929]]
Comparando imagen f1ja 'Dataset/Val1Prueba/Bovino38/24.15[M][000][0]_38.jpg' con 'Dataset/Val1Prueba/Bovino18/55.64[M][000][0]_18.jpg':
Valor de la predicción: [[0.00939620]]

```

Figura 44: Valores de predicciones con 1 imagen aleatoria.

En la Fig 44, se ve un caso similar al anterior. Se deja una imagen fija a comparar con otras aleatorias donde se realizó el código (Anexo A.10). Aunque en la mayoría de los casos presenta un valor correcto de acuerdo a las imágenes comparadas, en algunos de comparar un mismo bovino arroja un valor pequeño que dependiendo el umbral se tomaría como 1 o 0. Conforme a lo observado, se indica la necesidad de fijar un umbral con una mejor referencia y no simplemente aleatoriamente.

En consecuencia, una de las formas adecuadas para realizar la estimación del umbral fue a través de la curva ROC que permite ver la cantidad de verdaderos positivos en relación con los falsos positivos. Se realizó un código (Anexo A.11), que permitiera evaluar diferentes valores de umbral creando los pares de imágenes del conjunto de validación para que fueran empleadas en el modelo de redes siamesas creando las etiquetas de la predicción. Con esto, se realizaron dos esquemas para diferentes valores de umbral que se muestran a continuación:




Figura 45: Curva ROC para rango de valores 0.0 a 1.0

Tabla 3: Tamaño muestral resultante

Bovino	Entrenamiento	Validación	Test
1	9	3	3
7	9	3	2
8	9	3	1
11	15	5	4
12	9	3	1
18	21	7	4
19	12	4	1
21	27	9	3
27	51	17	9
29	9	3	3
33	24	8	2
34	12	4	3
35	9	3	1
36	24	8	2
38	15	5	4
43	42	14	5
49	15	5	1
50	18	6	2
55	15	5	3
56	9	3	3
57	12	4	4
62	9	3	2
64	24	8	1
70	30	10	3
72	33	11	4
75	24	8	2
78	12	4	3

Tal como se evidencia en la Fig 45, los valores donde se presenta una mayor tasa de verdaderos positivos es en un valor de 0.10. No obstante, se tiene una tasa de falsos positivos alta que en la aplicación del proyecto no es bueno. Por otro lado, tampoco se quiso dejar una tasa de verdaderos positivos muy bajo. Por consiguiente, se tomó el rango entre 0.2 y 0.4 para dejar un equilibrio entre ambas métricas que llevara a un correcto desempeño. En la siguiente figura, se muestra más detalladamente los valores en este rango:




Figura 46: Curva ROC para rango de valores 0.01 a 0.50

En la Fig 46, se aprecia un buen equilibrio entre la TPR y la FPR en el umbral de 0.24 al obtener valores aproximados de 0.5 y 0.1 respectivamente. De esta manera, se llevó a cabo la creación de la matriz de confusión modificando el valor del umbral para evaluar las métricas establecidas con las condiciones vistas en el apartado 7.4.3.

Tabla 4: Matriz de confusión con umbral 0.24.

2868	403
154	145

De la ecuación 1

$$ACC = \frac{2868 + 145}{2868 + 145 + 403 + 154} = \mathbf{0.84398} \quad (8)$$

De la ecuación 2

$$PPV = \frac{2868}{2868 + 403} = \mathbf{0.87679} \quad (9)$$

De la ecuación 3

$$NPV = \frac{145}{145 + 154} = \mathbf{0.48495} \quad (10)$$

De la ecuación 4

$$TPR = \frac{2868}{2868 + 154} = \mathbf{0.94904} \quad (11)$$

De la ecuación 5

$$TNR = \frac{145}{145 + 403} = \mathbf{0.26459} \quad (12)$$

De la ecuación 6

$$F1 = \frac{2 * 2868}{2 * 2868 + 403 + 154} = \mathbf{0.91149} \quad (13)$$

De la ecuación 7

$$MCC = \frac{2868 * 145 - 403 * 154}{\sqrt{(2868 + 403)(2868 + 154)(145 + 403)(145 + 154)}} = \mathbf{0.27799} \quad (14)$$

11. Conclusiones y recomendaciones

- La utilización de imágenes que contienen una o varias vacas depende del propósito específico de cada aplicación:
 - Para la detección, donde el objetivo principal es identificar la presencia de ganado en un área determinada, el uso de imágenes que muestran varias vacas puede ser más eficiente. Esto se debe a que estas imágenes proporcionan una visión general del entorno y permiten detectar la presencia de múltiples animales en una sola toma. Esto es especialmente útil en áreas extensas donde la densidad de ganado es alta y se necesitan métodos rápidos para identificar la presencia de animales en el terreno.
 - Por otro lado, en el caso de la identificación individual de vacas, donde el objetivo es distinguir y seguir a cada animal de forma individual, el uso de imágenes que muestran una sola vaca es preferible. Estas imágenes proporcionan una visión más clara y detallada de cada animal, lo que facilita la extracción de características únicas para su identificación, como patrones faciales o marcas distintivas. Además, al centrarse en una sola vaca, se minimiza la confusión y se simplifica el proceso de identificación, lo que puede mejorar la precisión del sistema.
- Un coeficiente de Matthews de 0.27799, sugiere una correlación moderada entre las predicciones y las observaciones, en un escenario donde se buscaba identificar vacas sabiendo que se contaba con un solo ángulo de captura. Este valor proporciona indicios de que el modelo tiene cierta capacidad para realizar esta tarea. Aunque la correlación no es muy alta, la presencia de una correlación sugiere que el modelo puede tener cierta utilidad en la identificación de vacas en tales condiciones. Observando las métricas de F1 y ACC, obtuvieron un valor alto demostrando un alto desempeño en el modelo. No obstante, el valor del MCC indica un desbalance en las muestras recopiladas, provocando de igual manera un desbalance en los valores predichos de la clase positiva, en este caso 1. De esta manera, en la fila negativa se tiene un error aproximado del 50 % en la proporción de 154 con 145, mientras que en la fila positiva se tiene un error mucho más pequeño gracias a la proporción de 403 en 2868. Sin embargo, para lograr niveles más altos de precisión y fiabilidad, pueden ser necesarias mejoras adicionales en el modelo, así como una mayor variedad en las muestras de los bovinos.
- Una futura integración de sistemas de detección e identificación de bovinos promete revolucionar la gestión agrícola en Colombia. Al unir estas tecnologías, los agricultores podrán monitorear de manera precisa y eficiente el comportamiento y la salud del ganado, optimizando los procesos de manejo y aumentando la productividad. Esto no solo mejorará la calidad de vida de los animales, sino que también impulsará la rentabilidad y la sostenibilidad de las operaciones ganaderas, contribuyendo así al crecimiento y la competitividad del sector agrícola colombiano en el futuro.

12. Referencias

Referencias

- [1] “Conoce el manejo y beneficios del bienestar animal en bovinos”. Agrotendencia.tv. Accedido el 14 de septiembre de 2023. [En línea]. Disponible: <https://agrotendencia.tv/agropedia/bovino/bienestar-animal-en-produccion-bovina-un-desafio/>
- [2] R. A. Brockway, “Desafíos del sector bovino de carne”. [En línea]. Disponible en: <http://www.odepa.gob.cl>
- [3] “Identificación y registro del ganado bovino. Regulación.” Ministerio de Agricultura, Pesca y Alimentación. Accedido el 14 de septiembre de 2023. [En línea]. Disponible: <https://www.mapa.gob.es/es/ganaderia/legislacion/regulacion-identificacion-bovino.aspx>
- [4] “Home - AgroGlobal”. AgroGlobal. Accedido el 14 de septiembre de 2023. [En línea]. Disponible: <https://agroglobalcampus.com/>
- [5] E. L. Sector, P. En, y E. L. Mundo, “Transformando el sector pecuario a través de los Objetivos de Desarrollo Sostenible”. [En línea]. Disponible en: <http://www.fao.org/publications/es>
- [6] “Maltrato a animales de granja | Igualdad Animal”. Igualdad Animal. Accedido el 24 de agosto de 2023. [En línea]. Disponible: <https://igualdadanimal.org/problematicas/>
- [7] Los tres movimientos del animalismo | ¡Derechos Animales ya! Accedido el 24 de agosto de 2023. [En línea]. Disponible: <https://derechosanimalesya.org/los-tres-movimientos-del-animalismo/>
- [8] “Identificación animal, garantía de sanidad e inocuidad”. gob.mx. Accedido el 24 de agosto de 2023. [En línea]. Disponible: <https://www.gob.mx/agricultura/articulos/identificacion-animal-garantia-de-sanidad-e-inocuidad?idiom=es>
- [9] “Instituto Colombiano Agropecuario - ICA”. Instituto Colombiano Agropecuario - ICA. Accedido el 1 de agosto de 2023. [En línea]. Disponible: <https://www.ica.gov.co/areas/pecuaria/servicios/epidemiologia-veterinaria/censos-2016/censo-2018>
- [10] Sabana Centro Cómo Vamos. <https://sabanacentrocomovamos.org/wp-content/uploads/2020/05/Presentaci%C3%B3n-de-Resultados-ICV-2016.pdf> (accedido el 1 de agosto de 2023).
- [11] (2023, 01 de marzo). “Carneo y atracos tienen azotados a ganaderos de la Sabana de Bogotá | CONtexto Ganadero”. CONtexto Ganadero. Accedido el 1 de agosto de 2023. [En línea]. Disponible: <https://www.contextoganadero.com/regiones/carneo-y-atracos-tienen-azotados-ganaderos-de-la-sabana-de-bogota>
- [12] (2015, 30 de abril). “Ganaderos pierden dinero por cada día abierto de sus vacas”: Decuadro | CONtexto Ganadero”. CONtexto Ganadero. Accedido el 1 de agosto de 2023. [En línea]. Disponible: <https://www.contextoganadero.com/reportaje/ganaderos-pierden-dinero-por-cada-dia-abierto-de-sus-vacas-decuadro>

- [13] Segura, J. (2023, 13 de febrero). “Ganaderos denuncian que siguen siendo víctimas de robo de ganado en siete departamentos del país”. Blu Radio. Accedido el 1 de agosto de 2023. [En línea]. Disponible: <https://www.bluradio.com/economia/ganaderos-siguen-siendo-victimas-de-robo-de-ganado-en-siete-departamentos-del-pais-rg10>
- [14] F. Andrés, D. Bernal, C. Andrés, y F. Gómez, “Análisis de productividad de ganado lechero holstein y jersey en dos fincas de La Sabana de Bogotá”, 2006. [En línea]. Disponible en: https://ciencia.lasalle.edu.co/administracion_agronegocios
- [15] S. Kumar et al., “Deep learning framework for recognition of cattle using muzzle point image pattern”, *Measurement (Lond)*, vol. 116, pp. 1–17, feb. 2018, doi: 10.1016/j.measurement.2017.10.064.
- [16] A. Salama, A. E. Hassanien, y A. Fahmy, “Sheep Identification Using a Hybrid Deep Learning and Bayesian Optimization Approach”, *IEEE Access*, vol. 7, pp. 31681–31687, 2019, doi: 10.1109/ACCESS.2019.2902724.
- [17] D. A. Sant’Ana et al., “Computer vision system for superpixel classification and segmentation of sheep”, *Ecol Inform*, vol. 68, may 2022, doi: 10.1016/j.ecoinf.2021.101551.
- [18] Z. Li, X. Lei, y S. Liu, “A lightweight deep learning model for cattle face recognition”, *Comput Electron Agric*, vol. 195, abr. 2022, doi: 10.1016/j.compag.2022.106848.
- [19] C. Cai y J. Li, “Cattle face recognition using local binary pattern descriptor”, en *2018 International Conference on Bangla Speech and Language Processing (ICBSLP)*, Sylhet, Bangladesh, 2018, pp. 1-6, doi: 10.1109/ICBSLP.2018.8554800.
- [20] X. Li et al., “Detail retaining convolutional neural network for image denoising”, *J Vis Commun Image Represent*, vol. 71, ago. 2020, doi: 10.1016/j.jvcir.2020.102774.
- [21] Y. Quan, Y. Chen, Y. Shao, H. Teng, Y. Xu, y H. Ji, “Image denoising using complex-valued deep CNN”, *Pattern Recognit*, vol. 111, mar. 2021, doi: 10.1016/j.patcog.2020.107639.
- [22] W. Andrew, J. Gao, S. Mullan, N. Campbell, A. W. Dowsey, y T. Burghardt, “Visual identification of individual Holstein-Friesian cattle via deep metric learning”, *Comput Electron Agric*, vol. 185, jun. 2021, doi: 10.1016/j.compag.2021.106133.
- [23] IEEE Computer Society., *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*: date, 7-12 June 2015.
- [24] H. Qin, J. Yan, X. Li, y X. Hu, “Joint Training of Cascaded CNN for Face Detection”, en *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, IEEE Computer Society, dic. 2016, pp. 3456–3465. doi: 10.1109/CVPR.2016.376.
- [25] D. E. Espinoza, O. Peter, I. Jorquera, G. Profesor, G.: Claudio, y C. Figueroa, “Reconocimiento Facial”, Pontificia Universidad Católica de Valparaíso, Chile, 2015. [Online]. Disponible en: http://opac.pucv.cl/pucv_txt/txt-1000/UCD1453_01.pdf

- [26] E. Calderón López, “Análisis comparativo de técnicas de reconocimiento facial”, Tesis de Ingeniería en Computación, Universidad Autónoma del Estado de México, Texcoco, México, 2016. [Online]. Disponible en: <https://core.ac.uk/reader/80528520>
- [27] Y.-Q. Wang, “An Analysis of the Viola-Jones Face Detection Algorithm”, *Image Processing Online*, vol. 4, pp. 128–148, jun. 2014, doi: 10.5201/ipol.2014.104.
- [28] Y. chen Wu y J. wen Feng, “Development and Application of Artificial Neural Network”, *Wirel Pers Commun*, vol. 102, núm. 2, pp. 1645–1656, sep. 2018, doi: 10.1007/s11277-017-5224-x.
- [29] C. Alberto Ruiz, M. S. Basualdo, y D. J. Matich, “Cátedra: Informática Aplicada a la Ingeniería de Procesos-Orientación I Redes Neuronales: Conceptos Básicos y Aplicaciones”.
- [30] “¿Qué son las redes neuronales convolucionales? | IBM”. IBM - Deutschland | IBM. Accedido el 24 de agosto de 2023. [En línea]. Disponible: <https://www.ibm.com/es-es/topics/convolutional-neural-networks>
- [31] “TFG-2402-Artola”. Accedido el 24 de agosto de 2023. [En línea]. Disponible: <https://idus.us.es/bitstream/handle/11441/89506/TFG-2402-ARTOLA.pdf?sequence=1&isAllowed=y>
- [32] X. Bastidas. “Redes Siamesas: aplicación de deep learning para la validación de identidad - ReconoSER ID”. ReconoSER ID. Accedido el 6 de septiembre de 2023. [En línea]. Disponible: <https://reconoserid.com/redes-siamesas-aplicacion-de-deep-learning-para-la-validacion-de-identidad/>
- [33] “Facial recognition cattle”. Home - University of New England (UNE). Accedido el 24 de agosto de 2023. [En línea]. Disponible: <https://www.une.edu.au/connect/news/2021/12/facial-recognition-comes-for-cattle>
- [34] J. Martínez, Profesor : L. De Mingo, “Reconocimiento de imágenes mediante redes neuronales convolucionales”, Universidad Politécnica de Madrid, España, s.f. [Online]. Disponible: https://oa.upm.es/53050/1/TFG_JAVIER_MARTINEZ_LLAMAS.pdf
- [35] “¿Qué es SAM, la revolución en segmentación de imágenes mediante IA?” Agencia-IA. Accedido el 16 de septiembre de 2023. [En línea]. Disponible: <https://agencia-ia.com/que-es-sam-la-revolucion-en-segmentacion-de-imagenes-mediante-ia/>
- [36] “U-NET : todo lo que tienes que saber sobre la red neuronal de Computer Vision”. Formación en ciencia de datos | DataScientest.com. Accedido el 16 de septiembre de 2023. [En línea]. Disponible: <https://datascientest.com/es/u-net-lo-que-tienes-que-saber>
- [37] R. Rodríguez. “Detección de objetos I: YOLO”. lamaquinaoraculo. Accedido el 16 de septiembre de 2023. [En línea]. Disponible: <https://lamaquinaoraculo.com/deep-learning/deteccion-de-objetos/>

A. Anexos

Se incluyen los anexos que respaldan la propuesta del proyecto.

- A.1. Tabla en excel para el registro de los bovinos.**
- A.2. Base de datos creada.**
- A.3. Cálculo de tamaño de la red neuronal.**
- A.4. Código implementado de Redes Siamesas**
- A.5. Protocolo de pruebas**
- A.6. Script realizado para etiquetado rápido**
- A.7. Código de prueba para dos imágenes fijas**
- A.8. Código para Matriz de Confusión**
- A.9. Código de prueba textual para dos imágenes aleatorias**
- A.10. Código de prueba textual para una imagen fija**
- A.11. Código para Curva ROC**
- A.12. Modelo de redes siamesas creado y entrenado**

Enlace a Archivos: <https://www.dropbox.com/scl/fo/bffye01t5hkhpy9nrr6/AHVPA6j261DUD80iPKe0wmrlkey=ggin804k0edmayqiyq40klv66&st=7aoecobo&dl=0>